

Wechselrichter-Kommunikation und Solarleistungsprognose

Masterthesis
von

Fabian Kern

am Institut für Angewandte Informatik und Formale Beschreibungsverfahren (AIFB)
der Fakultät für Wirtschaftswissenschaften

Referent:	Prof. Dr. Hartmut Schneck
Betreuer:	Dipl.-Inform. Daniel Pathmaperuma

Bearbeitungszeit: 1. April 2013 – 30. September 2013

Ich erkläre hiermit, dass ich die vorliegende Arbeit selbständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet, die wörtlich oder inhaltlich übernommen Stellen als solch ekenntlich gemacht und die Satzung des Karlsruher Instituts für Technologie (KIT) zur Sicherung guter wissenschaftlicher Praxis beachtet habe.

Karlsruhe, den 30. September 2013

Inhaltsverzeichnis

1	Einleitung	1
1.1	Aufgabenstellung und Zielsetzung	1
1.2	Vorgehensweise	2
1.3	Aufbau der Arbeit	3
2	Grundlagen	4
2.1	Photovoltaikanlage (PV-Anlage)	4
2.2	Solarstrahlung	5
2.3	Meteorologische Einflüsse auf die PV-Anlage	6
2.4	Wetterdienst	7
2.4.1	Anforderungen	7
2.4.2	Open Weather Map	8
2.5	Kommunikation mit SMA-Wechselrichter	8
2.5.1	Anforderungen	8
2.5.2	SMA Sunny Explorer	8
2.5.3	SMA-Bluetooth	9
2.5.4	SMAspot	9
2.6	Raspberry Pi	9
3	Stand der Technik	11
3.1	Physikalische Modellierung	11
3.2	Statistische Zeitreihenanalysen und künstliche neuronale Netze (KNN)	14
3.3	Zusammenfassung	15
4	Ausgewählte Prognosemodelle	16
4.1	Physikalisches Modell	16
4.1.1	Berechnung der auf das PV-Modul treffende Solarstrahlung . .	17
4.1.2	Simulation des Photovoltaikmoduls	20
4.1.3	Simulation des Wechselrichters	22
4.1.4	Berechnung der resultierenden PV-Leistung	23
4.2	Künstliches Neuronales Netz	23
4.2.1	Lernalgorithmus - Backpropagation	24

4.2.2	Rekursives Neuronales Netz (RNN)	25
5	Implementierung	27
5.1	Aufbau der Datenbasis	27
5.1.1	Abrufen/Speichern der PV-Leistung	27
5.1.2	Abrufen/Speichern aktueller Wetterinformationen	28
5.1.3	Abrufen/Speichern der Wettervorhersage	29
5.1.4	Fusionierung der PV-Leistungs- und Wetterinformationen . . .	29
5.2	PV-Leistungsprognose	30
5.2.1	Physikalisches Modell	30
5.2.2	Künstliches Neuronales Netz (KNN)	33
5.3	Zusammenfassung	33
6	Evaluierung	35
6.1	Evaluationskriterien	36
6.2	Physikalisches Modell	37
6.3	Künstliches Neuronales Netz	42
6.4	Wetterprognose	44
6.5	Laufzeit	46
6.6	Zusammenfassung	47
7	Zusammenfassung und Ausblick	48
A	Properties-Datei	50
B	Datenbankschemata	52
C	Fehlertabellen der KNNs bei einem Eingabeneuron	55
D	Wetterprognose	60
D.1	Vorhersage der Wetterparameter für den gesamten Vorhersagehorizont	60
D.2	Prognosefehler in Abhängigkeit des Vorhersagehorizontes	63
E	Laufzeitanalyse	65
F	Datenträgerinhalt	66
	Literaturverzeichnis	67

Abbildungsverzeichnis

2.1	Aufteilung der Solarstrahlung in ihre direkten und diffusen Anteile. ([Quas13])	6
4.1	Bestimmung des Sonneneinfallswinkels. [Quas13]	18
4.2	Wirkungsgrad des Wechselrichters SMA Sunny Boy 3000TL-20 basierend auf der Ausgangsleistung. [SMA10]	23
4.3	Ein einfaches KNN.	24
4.4	Abbildung einer Sigmoidfunktion.	25
4.5	Die Architektur eines einfachen Elman-RNN. (nach [Patt97])	26
6.1	Vergleich der Berechnung des physikalischen Modells mit den gemessenen Werten.	38
6.2	Zeitlicher Verlauf der auf das PV-Modul treffenden Solarstrahlung.	39
6.3	Der vom Modell berechnete Wirkungsgradverlauf des PV-Moduls in Abhängigkeit der Solarstrahlung.	39
6.4	Der vom Modell berechnete Wirkungsgradverlauf des Wechselrichters in Abhängigkeit von der Ausgangsleistung.	40
6.5	Vergleich der gemessenen PV-Leistung mit der berechneten Leistung auf der Basis von gemessenen und vorhergesagten Wetterdaten.	41
6.6	Vergleich der Leistungsberechnung von Kombination 1, 5 und 6 mit der tatsächlich gemessenen Leistung. Die x-Achse zeigt den Zeitverlauf in Stunden an. Es handelt sich dabei um vier aufeinanderfolgende Tage ab dem 19.08.2013.	43
6.7	Vergleich der Prognosekurven beider Modelle basierend auf Wettervorhersageinformationen.	44
6.8	Entwicklung des relativen RMSE bezüglich des Vorhersagehorizonts.	45

6.9 Die Trainingsdauer des KNNs unter Verwendung der Eingabekombi- nation 1.	46
B.1 Schema der Tabelle pv_data.	52
B.2 Schema der Tabelle pv_energy.	52
B.3 Schema der Tabelle solpos.	52
B.4 Schema der Tabelle current_weather.	53
B.5 Schema der Tabelle weather_forecast.	53
B.6 Schema der Tabelle power_forecast.	54
D.1 Verlauf der vorhergesagten und gemessenen Wolkenbedeckung.	60
D.2 Verlauf der vorhergesagten und gemessenen Luftfeuchtigkeit.	61
D.3 Verlauf des vorhergesagten und gemessenen Niederschlags.	61
D.4 Verlauf des vorhergesagten und gemessenen Luftdrucks.	61
D.5 Verlauf der vorhergesagten und gemessenen Temperatur.	62
D.6 Verlauf der vorhergesagten und gemessenen Windgeschwindigkeit.	62
D.7 Fehleranalyse der Wolkenbedeckung bezüglich des Vorhersagehorizonts.	63
D.8 Fehleranalyse des Luftdrucks bezüglich des Vorhersagehorizonts.	63
D.9 Fehleranalyse des Niederschlags bezüglich des Vorhersagehorizonts.	64
D.10 Fehleranalyse der Temperatur bezüglich des Vorhersagehorizonts.	64
D.11 Fehleranalyse der Windgeschwindigkeit bezüglich des Vorhersageho- rizonts.	64

Tabellenverzeichnis

2.1	Spezifikation des verwendeten Raspberry Pi Model B Rev. 2. [Pi13]	10
4.1	Koeffizienten des CR-Modells.	17
4.2	Azimutwinkel der Sonne.	19
4.3	Eine Auswahl unterschiedlicher Albedo-Werte.	20
4.4	γ -Werte für ausgewählte Moduleinbauarten. [LSHH ⁺ 11]	21
6.1	Korrelationskoeffizienten der Eingabemerkmale.	36
6.2	Fehler des physikalischen Modells für den Zeitraum vom 30.05.2013 bis 14.09.2013 unter Verwendung gemessener Wetterinformationen.	37
6.3	Fehler des physikalischen Modells für den Zeitraum vom 29.08.2013 bis 13.09.2013 unter Verwendung von Wettervorhersageinformationen.	40
6.4	Fehler des physikalischen Modells für den Zeitraum vom 29.08.2013 bis 13.09.2013 unter Verwendung von gemessenen Wetterdaten.	41
6.5	Prognosefehler der KNNs mit verschiedenen Eingabekombinationen. Die grün markierten Werte stellen jeweils den kleinsten Fehler und somit das optimale KNN dar.	43
6.6	Beschreibung der Eingabekombinationen.	43
6.7	Vergleich des physikalischen Modells und des KNNs auf Basis von Wettervorhersageinformationen.	44
6.8	Mittelwert, Varianz, Standardabweichung und Fehlerwerte der Wetterdaten.	45
6.9	Trainingsdauer des KNNs mit den empfohlenen Eingabeparametern, drei verborgenen Neuronen und 1426 Datensätzen auf dem Raspberry Pi.	47

C.1	Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Sonnenazimut.	55
C.2	Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Wolkenbedeckung.	56
C.3	Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Sonnenhöhe.	56
C.4	Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter extraterrestrische Globalstrahlung.	57
C.5	Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Tagesstunde.	57
C.6	Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter relative Luftfeuchtigkeit.	58
C.7	Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Niederschlag.	58
C.8	Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Luftdruck.	59
C.9	Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Temperatur.	59
E.1	Analyse der Trainingsdauer des empfohlenen KNNs unter Verwendung der Eingabekombination 1.	65

Listings

5.1	Auszug der CSV-Exportdatei des SMA-Wechselrichters.	28
A.1	Properties-Date zur Konfiguration der implementierten Applikationen.	50

1. Einleitung

Die Bundesregierung verabschiedete im Januar 2010 das Energiekonzept 2050, in dem das Ziel formuliert ist bis zum Jahr 2050 80 % der Stromerzeugung aus erneuerbaren Energien zu gewinnen (vgl. [BMWi10]). Zudem wurde in Folge der Kernschmelze in Fukushima im Jahr 2011 der Ausstieg aus der Atomenergie bis zum Jahr 2022 entschieden. Im Jahr 2012 betrug der Anteil an erneuerbaren Energien 22 % der gesamten Stromproduktion, 4,5 % entfielen dabei auf Photovoltaikanlagen (vgl. [BMWi12]). Der Vorteil konventioneller Stromerzeugung liegt in der Möglichkeit auf Nachfrageänderungen reagieren zu können. Eine solche Kontrolle ist bei erneuerbaren Energien oft nicht möglich. Deshalb muss ein Umdenken von bedarfsgerechter Stromerzeugung hin zu einem erzeugungsgerechten Stromverbrauch stattfinden (Demand-Side-Management). Durch Änderungen am Erneuerbare-Energien-Gesetz (EEG) ist es zudem inzwischen günstiger erzeugten PV-Strom selbst zu verbrauchen, anstatt ihn in das Stromnetz einzuspeisen (vgl. [Quas12]). Aus diesem Grund sollte Strom dann verbraucht werden, wenn er durch Eigenproduktion verfügbar ist. Um diese Zeitpunkte zu prognostizieren ist eine möglichst genaue Vorhersage der zu erwartenden Leistungserträge der PV-Anlage notwendig. Diese Prognosen können in einem Home Energy Management System eingesetzt werden, um den Stromverbrauch des Hauses optimal an die Eigenerzeugung aus der PV-Anlage anzupassen.

1.1 Aufgabenstellung und Zielsetzung

Die Aufgabenstellung dieser Arbeit kann in zwei Teilaufgaben unterteilt werden. Zum einen soll eine kabellose Kommunikation über Bluetooth mit einem SMA-Solar-Wechselrichter zum Auslesen der Erzeugungshistorie ermöglicht werden. Zum anderen sollen Wetterprognosen verwendet werden, um die Leistungserzeugung einer PV-Anlage für einen Vorhersagehorizont von 24 Stunden zu prognostizieren.

Ziel ist es die Prognosen mit möglichst geringen finanziellen Aufwand und Informationen über die verwendete Anlage zu realisieren. Aus diesem Grund wird als Hardware ein Raspberry Pi benutzt, auf dem die Prognosen berechnet werden. Die verwendeten Dienste und Implementierungen müssen kostenlos und frei zur Verfügung stehen. Es soll ein künstliches neuronales Netz (KNN) realisiert werden, dass sich an Veränderungen der Einsatzumgebung (z. B. Jahreszeit oder zunehmende Verschmutzung des Moduls) anpassen kann. Die Prognose soll lokal und individuell für eine Anlage erstellt werden.

1.2 Vorgehensweise

Nachfolgend wird kurz das Vorgehen zur Umsetzung dieser Arbeit beschrieben. Zuerst wird eine Literaturrecherche durchgeführt, bei der existierende Verfahren und Modelle zur Vorhersage der Photovoltaikleistung recherchiert und auf ihre Anwendbarkeit in der Arbeit bewertet werden. Zudem werden die benötigten Eingabeparameter der Modelle identifiziert. Basierend auf diesen Erkenntnissen werden Kriterien formuliert, die der Wetterdienst erfüllen muss. Es werden verschiedene Wetterdienste gegen diese Kriterien getestet und so der Dienst für diese Arbeit ausgewählt. Um aktuelle und historische Leistungsdaten der Photovoltaikanlage zu erhalten, werden bestehende Implementierungen zur kabellosen Kommunikation über Bluetooth mit dem Wechselrichter ermittelt, getestet und für die Arbeit ausgewählt. Zur Kommunikation mit dem Wetterdienst wird auf eine bereits existierende Java-Bibliothek zurückgegriffen, an der Änderungen vorgenommen und Fehler beseitigt werden müssen, um diese in der Arbeit verwenden zu können. Die Berechnung der Sonnenposition wird durch den *SOLPOS*-Algorithmus realisiert. Der Quellcode des Algorithmus ist in der Programmiersprache C kostenlos im Internet herunterladbar und muss in Java übersetzt werden. Die Implementierung der künstlichen neuronalen Netze soll mittels bereits erprobten und getesteten Frameworks realisiert werden. Dazu werden existierende Implementierungen miteinander verglichen und in dieser Arbeit verwendet. Es wird eine Datenbasis benötigt, mit der die implementierten Modelle trainiert und evaluiert werden können. Diese besteht aus den Wetterinformationen, der Sonnenposition, der extraterrestrischen Strahlung und der gemessenen Leistung der PV-Anlage. Dazu werden Anwendungen implementiert, die die notwendigen Daten fusioniert, auf Fehler prüft, gegebenenfalls korrigiert und in einer Datenbank speichert. Zur Identifizierung der optimalen Struktur des KNNs werden verschiedene Kombinationen von Eingabeparametern und unterschiedlicher Anzahl von verborgenen Neuronen implementiert und getestet. Zudem wird das physikalische Modell implementiert. Um die Eignung der implementierten Modelle zur Leistungsprognose einschätzen zu können, müssen diese mit Testdaten evaluiert werden. Basierend

auf diesen Erkenntnissen wird eine Anwendung entwickelt, die das Modell mit der größten Genauigkeit für die Leistungsprognose verwendet.

1.3 Aufbau der Arbeit

Kapitel 1 gibt eine kurze Einleitung in das Thema und zeigt die Vorgehensweise zur Umsetzung der Arbeit auf. In Kapitel 2 werden die Grundlagen, die für das weitere Verständnis der Arbeit notwendig sind, erklärt. Es umfasst eine kurze Beschreibung der Funktionsweise von Photovoltaikanlagen, den Einfluss der Solarstrahlung und anderen Wetterparametern auf die PV-Leistung und die verwendeten Technologien zur Implementierung der Prognoseanwendung. Einen Überblick über die in der Literatur vorgestellte Verfahren und Modelle zur Prognose der PV-Leistung sind in Kapitel 3 zu finden. Die für diese Arbeit ausgewählten Modelle werden in Kapitel 4 im Detail erklärt und in Kapitel 5 implementiert. Die Evaluierung der implementierten Modelle ist in Kapitel 6 beschrieben. In Kapitel 7 werden die wichtigsten Erkenntnisse aus der Arbeit zusammengefasst und eine Handlungsempfehlung gegeben.

Im Anhang dieser Arbeit sind die Konfigurationsdatei für die Prognoseanwendung (Anhang A), die Datenbankschemata (Anhang B), detaillierte Tabellen und Abbildungen der Evaluierung der KNNs (Anhang C), der Wetterprognose (Anhang D) und der Laufzeitanalyse (Anhang E) zu finden. Der Inhalt der beigelegten CD ist in Anhang F beschrieben.

2. Grundlagen

In diesem Kapitel werden die Grundlagen zum weiteren Verständnis dieser Arbeit beschrieben. Dazu gehört eine kurze Einführung in die Funktionsweise von Photovoltaikanlagen, der Einfluss von meteorologischen Bedingungen und die Besonderheiten und Wichtigkeit der Solarstrahlung in Bezug auf die PV-Anlage. Zudem werden Anforderungen an den verwendeten Wetterdienst und an die Kommunikation mit dem SMA-Wechselrichter formuliert, mögliche Kandidaten vorgestellt und zur weiteren Verwendung in der Arbeit ausgesucht.

2.1 Photovoltaikanlage (PV-Anlage)

Quaschnig beschreibt in [Quas13] Photovoltaik als die „direkte Umwandlung von Sonnenlicht in Elektrizität“ unter der Ausnutzung des Photoeffekts. Dabei gilt, je höher die Anzahl an Lichtphotonen, die auf die Oberfläche des PV-Moduls treffen, desto höher ist der daraus gewonnene Strom. Bei konstanter Spannung ergibt sich der in Formel 2.1 gezeigte lineare Zusammenhang zwischen direkter Bestrahlungsstärke E_{Dir} (W/m^2) und elektrischer Leistung P (W) (vgl. [Watt09]).

$$P_{el} = U \cdot I \sim E_{Dir} \quad (2.1)$$

Ein PV-Modul besteht aus vielen Solarzellen, die ihre maximale Leistung bei einer bestimmten Spannung erreichen. Die Maximalleistung der Solarzelle wird als MPP (Maximum Power Point) oder Peak-Leistung bezeichnet. Mittels MPP-Tracking wird die Spannung so angepasst, dass die Solarzelle auch bei wechselnder Bestrahlungsstärke im maximalen Leistungsbereich arbeitet.

Unter dem Wirkungsgrad versteht man das Verhältnis der abgegebenen Leistung zur zugeführten Leistung. Formel 2.2 zeigt die Berechnung des Wirkungsgrads η

von Solarzellen, bei der die MPP-Leistung P_{MPP} durch das Produkt aus Bestrahlungsstärke E und der Fläche A der Solarzellen geteilt wird. Der Wirkungsgrad ist zudem von der Temperatur der Solarzelle abhängig, indem er bei zunehmender Temperatur sinkt.

$$\eta = \frac{P_{MPP}}{E \cdot A} \quad (2.2)$$

Wirkungsgrad, Peak-Leistung und weitere Parameter, die zum Vergleich von PV-Modulen wichtig sind, werden unter Standardtestbedingungen¹ (STC, Standard Test Conditions) im Labor ermittelt. Die dadurch erzielten Resultate übersteigen die Leistung unter natürlichen Bedingungen, weshalb häufig auch Messwerte unter Normalbetriebsbedingungen (NOTC, Normal Operating Test Conditions) angegeben werden. Unter NOTC-Bedingungen wird die tatsächliche Zelltemperatur (NOCT, Normal Operating Cell Temperature) bei $E = 800 \text{ W/m}^2$, 20°C Umgebungstemperatur, $Air - Mass = 1,5$ und einer Windgeschwindigkeit von 1 m/s angegeben. Im Durchschnitt liegt diese bei ca. 45°C .

Die von den PV-Modulen erzeugte Gleichspannung muss zum Eigenverbrauch oder zur Netzeinspeisung mittels eines PV-Wechselrichters in Wechselspannung transformiert werden. Der Wechselrichter ist für das oben genannte MPP-Tracking der PV-Module zuständig, indem er die DC-Spannung der PV-Module variiert. Um eine Netzeinspeisung zu ermöglichen, muss sich der Wechselrichter mit dem Netz bzgl. der Ausgangsspannung, Frequenz und Phasenlage synchronisieren. Zudem realisiert er Schutzfunktionen um die Anlage im Fehlerfall vom Stromnetz zu trennen.

2.2 Solarstrahlung

Die Solarstrahlung ist die von der Sonne emittierte Strahlung und ist maßgeblich für resultierende Leistung der PV-Anlage verantwortlich. Die auf die Erdatmosphäre senkrecht treffende, extraterrestrische Solarstrahlung entspricht im Jahresmittel 1360 W/m^2 und wird als Solarkonstante bezeichnet. Die extraterrestrische Solarstrahlung unterliegt jahreszeitlichen Schwankungen von 1412 W/m^2 im Winter und 1321 W/m^2 im Sommer, aufgrund der größeren Sonnenentfernung zur Erde im Sommer. Trotzdem werden im Sommer höhere PV-Leistungserträge erzielt, da der Elevationswinkel der Sonne größer und somit die Dämpfung der Solarstrahlung durch die Atmosphäre geringer ist. Zusätzlich hat der Sommer mehr Sonnenstunden pro Tag. Der im Winter kleinere Elevationswinkel kann teilweise durch das Neigen der PV-Module in Richtung der Solarstrahlung kompensiert werden. Bei der für die PV-Anlage nutzbare Solarstrahlung muss zwischen der Direkt- und Diffusstrahlung

¹Bestrahlungsstärke $E = 1000 \text{ W/m}^2$, Zelltemperatur $\vartheta = 25^\circ\text{C}$, Spektralverteilung des Lichts $Air - Mass = 1,5$

unterschieden werden. Die Direktstrahlung ist der Teil, der senkrecht auf das PV-Modul trifft. Die Diffusstrahlung ist dagegen der Anteil, der auf das PV-Modul fällt, nach der Absorption und Reflexion an Hindernissen (siehe Abbildung 2.1). Als Globalstrahlung wird die Summe aus Direkt- und Diffusstrahlung bezeichnet.




Abbildung 2.1: Aufteilung der Solarstrahlung in ihre direkten und diffusen Anteile. ([Quas13])

2.3 Meteorologische Einflüsse auf die PV-Anlage

Wie bereits in Kapitel 2.1 und 2.2 zu sehen war, hängt die Leistung der PV-Anlage von verschiedenen Komponenten und äußeren Einflüssen ab. In diesem Abschnitt soll der Zusammenhang von Wetterparametern und der Solarstrahlung bzw. der PV-Leistung aufgezeigt werden.

Gwandu und Creasey und Mekhilef et al. zeigen in [GwCr95, MeSK12], dass es einen nichtlinearen Zusammenhang zwischen der relativer Luftfeuchtigkeit und der auf das PV-Modul treffenden Globalstrahlung gibt. Bei größerer relativer Luftfeuchtigkeit ist der Wasseranteil in der Luft höher, wodurch die Strahlung gebrochen, reflektiert oder zerstreut wird und so die resultierende Globalstrahlung gedämpft ist. Der Zusammenhang ist nichtlinear, da die Wasserteilchen in der Atmosphäre ungleich verteilt sind. Zusätzlich kann diese Feuchtigkeit in die Module eindringen, wodurch es zu einer Leistungsminderung kommen kann. Mekhilef et al. zeigen außerdem, dass die Zelltemperatur bei höherer Windgeschwindigkeit fällt und somit der Wirkungsgrad der Solarzellen erhöht wird.

Die von Kasten und Czeplak in [KaCz80] entwickelte und von Muneer und Gul in [MuGu00] für weitere Gegenden verifizierte Relation der Wolkenbedeckung zur Globalstrahlung zeigt, je höher die Wolkenbedeckung, desto geringer ist die Solarstrahlung und somit die Leistung des PV-Moduls. Der Zusammenhang zwischen

Temperatur und PV-Leistung wurde bereits im Kapitel 2.1 erläutert, in dem der Wirkungsgrad der Solarzelle bei steigender Temperatur fällt. Die Menge des Niederschlags pro Quadratmeter, sowie ein geringer Luftdruck können als Indiz für eine größere Wolkenbedeckung genommen werden.

2.4 Wetterdienst

Für die Abschätzung der PV-Leistung sind Wetterdaten notwendig, die von Wetterdiensten zumeist kostenpflichtig bezogen werden können. In diesem Unterkapitel werden die Anforderungen gegenüber des Wetterdienstes für diese Arbeit definiert und der im Rahmen dieser Arbeit verwendete Dienst **Open Weather Map** vorgestellt.

2.4.1 Anforderungen

Wie bereits in Kapitel 1.1 erwähnt, muss beim Wetterdienstes auf einen kostenfreien Dienst zurückgegriffen werden. Der Dienst sollte aktuelle Wetterinformationen, eine Wettervorhersage für die nächsten 24 Stunden in stündlicher Auflösung und die Möglichkeit zur Abfrage historischer Wetterinformationen bieten. Historische Wetterdaten sind notwendig, um diese mit vorhandenen PV-Leistungsdaten fusionieren zu können und somit einen Datenbestand zum Training des künstlichen neuronalen Netzes aufzubauen. Die **Wetterinformationen** sollten folgende **Wetterparameter** beinhalten:

- Temperatur ($^{\circ}C$)
- Luftdruck (hPa)
- Relative Luftfeuchtigkeit (%)
- Wolkenbedeckung (%)
- Niederschlag (mm^3/m^2)
- Windgeschwindigkeit (m/s)
- Globalstrahlung (W/m^2)

Der Parameter *Globalstrahlung* wurde wieder gestrichen, da er nicht von kostenfreien Wetterdiensten zur Verfügung gestellt wird. Zusätzlich wird die **Auflösung der Wettervorhersage auf drei Stunden vergrößert**. Zum Abrufen der Wetterinformationen muss der Wetterdienst ein Application Programming Interface (API) zur Verfügung stellen.

2.4.2 Open Weather Map

Im Rahmen dieser Arbeit wird der kostenfreie Dienst Open Weather Map [Ukol13a] verwendet. Über eine API kann im *XML*- oder *JSON*-Format das aktuelle Wetter, die Wettervorhersage für die nächsten sieben Tage in 3-stündiger Auflösung und die historische Wetterdaten abgerufen werden. Laut Ukoloff [Ukol13b] basieren die Wetterinformationen auf den Messungen von über 40.000 professionellen (u. a. Flughäfen, Wetterstationen großer Städte) und privaten Messstationen. Privatpersonen haben die Möglichkeit, die Messungen eigener Wetterstationen über eine separate API Open Weather Map zur Verfügung zu stellen. Wettervorhersagen werden durch die Kombination von globalen Wettermodellen der amerikanischen NOAA (National Oceanic and Atmospheric Administration) und dem kanadischen Umweltministerium (Environment Canada) mit lokal gültigen Vorhersagemodellen und Daten aus lokalen Wetterstationen erstellt.

2.5 Kommunikation mit SMA-Wechselrichter

Dieses Unterkapitel definiert die Anforderungen an die Kommunikation mit einem SMA-Wechselrichter. Es werden zwei Open Source-Projekte und eine von SMA bereitgestellte Software beschrieben und verglichen. Diese können sowohl zur Überwachung also auch zum Export der PV-Leistungsdaten eingesetzt werden und realisieren so die Kommunikation mit dem Wechselrichter. Die Firma SMA bezeichnet sich in [SMA12] als „weltweit führend in der Entwicklung, der Produktion und dem Vertrieb von Solar-Wechselrichtern“, hat ihren Hauptsitz in Niestetal bei Kassel. Es beschäftigt mehr als 5000 Mitarbeiter und erwirtschaftete im Jahr 2012 einen Jahresumsatz von 1,5 Mrd. Euro. Im Rahmen dieser Arbeit wird der Wechselrichter SMA Sunny Boy 3000TL-20 verwendet, der Ertragsdaten der PV-Anlage in 5-minütiger Auflösung für die vergangenen 60 Tage zur Verfügung stellt.

2.5.1 Anforderungen

Die Kommunikation zwischen Wechselrichter und Raspberry Pi soll kabellos über Bluetooth erfolgen, der Konfigurationsaufwand möglichst gering sein und nur wenige Einstellungen erfordern, um den Datenaustausch zu ermöglichen.

2.5.2 SMA Sunny Explorer

Nahezu alle Wechselrichter im Sortiment von SMA unterstützen die kabellose Kommunikation über Bluetooth. Die proprietäre Software SMA Sunny Explorer ([SMA13]) kann zur Überwachung und Visualisierung der Leistung der Photovoltaik-Anlage eingesetzt werden. Da die Software nur für das Windows-Betriebssystem erhältlich ist und Leistungsdaten manuell exportiert werden müssen, ist sie nicht für den Einsatz auf einem Raspberry Pi geeignet.

2.5.3 SMA-Bluetooth

SMA-Bluetooth (vgl. [Coll12]) ist ein Open Source-Projekt, das die Kommunikation zwischen SMA-Wechselrichter und einem Computer mit Bluetooth-Adapter ermöglicht. Das Programm ist in C++ geschrieben, kann selbst kompiliert werden und ist somit auch auf einem Raspberry Pi lauffähig. Die aktuelle Version 0.18 vom Juni 2012 unterstützt die SMA Wechselrichter Sunny Boy 1700TL, 2100TL, 3000TL, 3000TLHF, 4000TL, 5000TL und 10000TL (Stand September 2013). Um eine Verbindung mit dem Wechselrichter herzustellen, muss der Typ des Wechselrichters, dessen Bluetooth-Adresse und das entsprechende Kennwort angegeben werden. Die ausgelesenen Leistungs- und Energiedaten werden im CSV²-Format gespeichert. Dabei werden die Daten tageweise in 5-minütiger und monatsweise in täglicher Auflösung gespeichert. Darüber hinaus können die Leistungsdaten automatisch an die Webseite www.pvoutput.org übertragen und dort visuell aufbereitet, betrachtet werden.

2.5.4 SMAspot

Das Open Source-Projekt *SMAspot* (vgl. [SMAs13]) stellt dieselben Möglichkeiten wie *SMA-Bluetooth* (siehe Abschnitt 2.5.3) zur Verfügung, kann ebenfalls selbst kompiliert werden und ist somit auf dem Raspberry Pi lauffähig. Unterstützt werden alle SMA-Wechselrichter, die über eine Bluetooth-Komponente verfügen. Die Konfiguration ist einfacher, da der genaue Typ des Wechselrichters nicht angegeben werden muss. Die Angaben der Bluetooth-Adresse und des entsprechenden Passworts sind ausreichend.

Im Rahmen dieser Arbeit wurde SMAspot aufgrund der größeren Anzahl unterstützter Wechselrichter, der aktiveren Entwicklungsgemeinschaft und der einfacheren Konfiguration verwendet.

2.6 Raspberry Pi

Um eine möglichst kostengünstige Realisierung zu gewährleisten wurde als Hardwaregrundlage ein Raspberry Pi verwendet. Es handelt sich dabei um einen Einplatinencomputer, der mit einem ARM-Prozessor ausgestattet ist. Als Betriebssystem kann Linux oder jedes andere Betriebssystem, das die ARM-Architektur unterstützt, auf einer SD-Karte installiert werden. Der Preis des verwendeten Modells beträgt ca. 40 Euro. Die detaillierten Spezifikationen des verwendeten Modells sind Tabelle 2.1 zu entnehmen. Zur kabellosen Kommunikation mit dem Heimnetzwerk und Wechselrichter wurden an die USB-Anschlüsse ein WLAN- und ein Bluetooth-Adapter angeschlossen.

²Comma-Separated-Values

Model	B
Revision	2
CPU	700 MHz ARM1176JZF-S
Arbeitsspeicher	512 MB
USB-Anschlüsse	2 (USB 2.0)
Videoausgang	HDMI, FBAS
Netzwerk	10/100 Mbit Ethernet
Betriebssystem	Raspbian (Debian Variante)
Leistungsaufnahme	5 V, 700 mA (3,5 W)

Tabelle 2.1: Spezifikation des verwendeten Raspberry Pi Model B Rev. 2. [Pi13]

3. Stand der Technik

Die in der Literatur genannten Modelle zur Vorhersage der PV-Leistung können unterteilt werden in die physikalische Nachbildung der Komponenten einer PV-Anlage, in die Vorhersage mittels statistischen Zeitreihenanalysen und in die Verwendung von künstlichen neuronalen Netzen.

3.1 Physikalische Modellierung

Eine Leistungsprognose durch die Modellierung der physikalischen Eigenschaften einer PV-Anlage wurde von Bofinger und Heilscher in [BoHe06] vorgestellt und von Lorenz et al. in [LSHH⁺11] verfeinert. Beide Modelle benötigen als Eingabeparameter die horizontale Globalstrahlung, die von Lorenz et al. als der wichtigste Teil bzgl. der Leistungsvorhersage bezeichnet wird.

Zur Vorhersage der Globalstrahlung existieren verschiedene Ansätze. Hammer et al. haben in [HHLL99] eine Möglichkeit präsentiert, die die Wolkenbewegung durch die Auswertung von Satellitenbildern vorhersagt. Wolken haben den größten Einfluss auf die Globalstrahlung. Die Autoren verwendeten ein Modell, das die Globalstrahlung unter wolkenfreien Bedingungen bestimmt und die Dämpfung der Globalstrahlung durch die Wolken berechnet. Dieser Ansatz erreicht bei einem Vorhersagehorizont von weniger als zwei Stunden sehr präzise Resultate. Darüber hinaus sind numerische Wettervorhersagen besser.

Für Globalstrahlungsvorhersagen zwischen sechs Stunden und bis zu mehreren Tagen liefern numerische Wettervorhersagen (engl. Numerical Weather Prediction, NWP) die besten Ergebnisse. Diese haben allerdings eine schlechte zeitliche und räumliche Auflösung, die aber laut Diagne et al. ([DDLb12]) durch Beobachtungen des Himmels vom Boden aus verbessert werden können. Zudem kann eine Korrektur durch Model Output Statistic (MOS, [GILo72]) angewendet werden, wie sie auch

von Bofinger und Heilscher in [BoHe06] eingesetzt wird. Dabei werden Messwerte lokaler Wetterstationen verwendet, die mit den Ergebnissen des NWP durch multilinare Regressionsgleichungen in Zusammenhang gebracht werden und so genauere Ergebnisse liefern.

Über das Europäische Zentrum für mittelfristige Wettervorhersagen (EZMW) können kostenpflichtige Vorhersagewerte für die Globalstrahlung in 3-stündiger Auflösung für bis zu drei Tage bezogen werden. Das EZMW setzt dafür ein globales Modell mit geringer räumlicher Auflösung ein. Lorenz et al. haben in [LHHB09] diese Vorhersagen in ihrer räumlichen und zeitlichen Auflösung verfeinert, sodass auch lokal gültige Globalstrahlungsvorhersagen getroffen werden können. Dies wurde durch die Kombination der EZMW-Vorhersage mit einem Modell zur Abschätzung der Globalstrahlung unter wolkenfreiem und -bedecktem Himmel erreicht. Dabei wurde festgestellt, dass bei einer Wolkenbedeckung von 40-80% der Vorhersagefehler am größten ist. Aus diesem Grund wurden zusätzlich lokale Globalstrahlungsmessungen durchgeführt und eine Bias-Korrektur für solche Wolkenverhältnisse durchgeführt.

Samani hat in [Sama00] eine Möglichkeit präsentiert, bei der unter Verwendungen der minimalen und maximalen Temperatur der Tagesdurchschnitt für die Globalstrahlung bestimmt werden kann. Dieses Verfahren eignet sich dann, wenn keine stündliche Prognose erstellt werden soll, sondern Tages- oder Wochendurchschnittswerte ausreichen. Neben Samani wurde u. a. auch in den Arbeiten von Almorox ([Almo11]), Bristow et al. ([BrCa84]), Supit und van Kappel ([SuvK98]) und Allen ([Alle97]) jeweils Tages- oder Wochendurchschnittswerte bestimmt.

Drei Modelle zur Globalstrahlungsabschätzung in stündlicher Auflösung auf Basis von wenigen herkömmlichen Wetterparametern haben Muneer und Gul in [MuGu00] vorgestellt. Das meteorologische Strahlungsmodell (MR-Modell) benötigt dafür die Temperatur und den Sonnenscheinanteil einer Stunde und liefert bei wolkenfreiem Himmel eine Strahlungsvorhersage mit einem durchschnittlichen Fehler von 9%, bei wolkenbedecktem Himmel von 25%. Das zweite Modell (CR-Modell) benötigt lediglich die Wolkenbedeckung zur Bestimmung der Globalstrahlung und das dritte Modell (PR-Modell) ist eine Kombination aus MR- und CR-Modell. Das PR-Modell überzeuge unter wolkenbedeckten Bedingungen, das MR-Modell bei wolkenfreiem Himmel. Das CR- und MR-Modell sind bei dazwischenliegenden Bedingungen gleich gut geeignet. Das CR-Modell kann im Rahmen dieser Arbeit aufgrund der vom Wetterdienst zur Verfügung gestellten Wolkenbedeckung zur Abschätzung der Globalstrahlung eingesetzt werden.

Zur Bestimmung der Strahlung auf eine geneigte Fläche wie den PV-Modulen gibt es verschiedene Ansätze. Grundsätzlich können iso- und anisotrope Modelle unterschieden werden. Isotrope Modelle wie sie z. B. von Liu und Jordan in [LiJo63] beschrieben wurden, gehen von einer gleichmäßigen Verteilung der Helligkeit am

Himmel aus. Das Modell von Liu und Jordan liefert gute Ergebnisse bei wolkenbedecktem Himmel, unterschätzt aber die Solarstrahlung bei wolkenfreiem oder nur teilweise bedecktem Himmel. Temps und Coulson haben in [TeCo77] ein anisotropes Modell unter wolkenfreien Bedingungen vorgestellt. Es eignet sich besonders gut für die Bestimmung der Solarstrahlung bei wolkenfreiem Himmel, überschätzt aber die Strahlung an wolkenbedeckten Tagen. Ein anisotropes Modell geht davon aus, dass die Helligkeit am Himmel nicht gleichverteilt, sondern am Horizont und in der Nähe der Sonne größer ist. Klucher hat daraufhin in [Kluc79] ein anisotropes Modell unter allen Wolkenbedingungen formuliert, das die Ansätze der beiden zuvor genannten Modelle kombiniert. Dies wird erreicht, indem der diffuse Anteil der Strahlung zur Globalstrahlung ins Verhältnis gesetzt wird. Sind diese gleich, so wird das Modell auf das isotrope Modell von Liu und Jordan reduziert. Je kleiner der diffuse Anteil zur Globalstrahlung ist, desto stärker fließt das Modell von Temps und Coulsen in die Abschätzung mit ein.

Perez et al. haben in [PSAS⁺86, PSIS⁺87] ein Modell präsentiert, das exaktere Ergebnisse liefert als das von Klucher, aber in seiner Berechnung sehr viel komplexer und aufwändiger ist. Noorian et al. haben in [NoMK08] u. a. die Modelle von Klucher und Perez et al. bzgl. ihrer Genauigkeit zwischen Juni und Oktober 2002 verglichen und als Fehlermaß den $rRMSE$ ¹ verwendet. Für eine nach Süden ausgerichtete PV-Anlage erreichte das Modell von Perez et al. einen $rRMSE = 11,17\%$, das von Klucher $rRMSE = 15,43\%$. Bei einem Experiment mit nach Westen ausgerichteten PV-Anlage lag der Fehler beim Modell von Perez et al. schon bei $rRMSE = 30,71\%$ und das Modell von Klucher bei $rRMSE = 37,97\%$. Das Modell von Klucher ist demnach im schlechtesten Fall lediglich um ca. $7,2\%$ ungenauer als das von Perez et al, weshalb in dieser Arbeit das Modell von Klucher bevorzugt wird.

Ein Modell zur Bestimmung des Wirkungsgrades von PV-Modulen wurde von Beyer et al. in [BBDH⁺04] vorgestellt. Es eignet sich sowohl für die Modellierung des Wirkungsgrades im MPP-Bereich von klassischen monokristallinen Siliziumzellen, als auch für moderne Dünnschicht-Siliziumzellen. Als Eingabeparameter benötigt das Modell neben der Modultemperatur und der auftreffenden Strahlung drei Modellparameter, die laut den Autoren zumeist aus dem Datenblatt abgelesen werden können.

Schmidt und Sauer haben in [ScSa96] ein Verfahren aufgezeigt, mit dem der Wirkungsgradverlauf eines Wechselrichters physikalisch nachgebildet wird. Dazu sind lediglich die Wirkungsgrade bei drei verschiedenen Teillasten des Wechselrichters notwendig, die in der Regel dem Datenblatt entnommen werden können. Dabei ist es egal, ob diese in Abhängigkeit der Eingangs- oder der Ausgangsleistung bestimmt

¹relative root-mean-square error, die Quadratwurzel des mittleren quadratischen Fehlers in Prozent.

wurden, da die Autoren eine Möglichkeit präsentiert haben diese ineinander umzurechnen.

Zur lokalen Prognose einer PV-Anlage sollte auch eine evtl. Beschattung der Anlage berücksichtigt werden. Allerdings erfordern die in der Literatur vorgeschlagenen Verfahren ([DPAA08, Vign07]) stets detaillierte Kenntnisse der Hindernisse, die das PV-Modul beschatten könnten. Dazu wird entweder die Sonnenposition bestimmt, um die Beschattung durch die Hindernisse zu berechnen ([DPAA08, Quas13]), oder die Bewegung des Schattens wird im Tagesverlauf manuell aufgezeichnet. Darauf basierend wird ein Beschattungsfaktor bestimmt, um den die auf das PV-Modul treffende Solarstrahlung gedämpft wird. Aufgrund des angestrebten Ziels, eine Prognose unter möglichst geringer Kenntnis der verwendeten Anlage und deren Umgebung zu erstellen, wird die Beschattung im physikalischen Modell nicht weiter betrachtet.

3.2 Statistische Zeitreihenanalysen und künstliche neuronale Netze (KNN)

Diagne et al. stellen in [DDL12] Verfahren basierend auf **statistischen Zeitreihenanalysen vor**. Das Persistenz-Modell ist dabei das einfachste. Es nimmt an, dass zum Zeitpunkt $t + 1$ derselbe Wert wie zum Zeitpunkt t auftritt. Der Zweck dieses Modells ist ein Vergleichsmodell für andere, komplexere Modelle. **Aufgrund des sehr naiven Ansatzes eignet es sich maximal für einen Vorhersagehorizont von einer Stunde**. ARMA-Modelle (Autoregressive Moving Average) sind lineare Modelle für stationäre, zeitdiskrete stochastische Prozesse. Sie bestehen aus den Teilmodellen AR- (autoregressives Modell) und MA-Modell (Moving Average, gleitender Durchschnitt). Diese eignen sich gut für Vorhersagen in Zeitreihen, wenn die zu betrachtende Zeitreihe einen linearen Zusammenhang besitzt. Voraussetzung für die Anwendung von ARMA-Modellen ist, dass die Zeitreihe stationär ist. **Für die Vorhersage von Solarstrahlung ist dies dann der Fall, wenn die Zeitreihe um saisonale Einflüsse bereinigt ist**. ARIMA-Modelle (Autoregressive Integrated Moving Average) dagegen können auch für Zeitreihenprognosen eingesetzt werden, die nichtstationär sind. Tao et al. haben in [TaSC10] ein Vorhersagenetzwerk vorgestellt, das für einen Zeithorizont von 24 Stunden die PV-Leistung in stündlicher Auflösung prognostizieren kann. Dazu wird ein nichtlineares autoregressives Modell mit **exogenen Eingabewerten** (Nonlinear Autoregressive Model with Exogeneous Inputs, NARX) verwendet. Das Netz bestimmt die PV-Leistung basierend auf berechneten Globalstrahlungswerten unter wolkenfreiem Himmel, der minimalen und maximalen Temperatur für den Vorhersagetag und einem Faktor, der die durchschnittliche Wolkenbedeckung für diesen Tag angibt. Das Netz erreichte nach einem Training mit einer Zeitreihe im Umfang von sechs Monaten bei der Evaluierung einen mittleren absoluten prozentualen Fehler von 16.5%.

In [YoSF07] von Yona et al. wurden feedforward (FFN) und rekursive neuronale Netze (RNN) miteinander verglichen, um die Solarstrahlung zu prognostizieren und damit die PV-Leistung abschätzen zu können. Dabei stellte sich heraus, dass RNNs aufgrund ihrer Kontextschicht besser geeignet sind.

3.3 Zusammenfassung

Zur Vorhersage der Leistung von PV-Anlagen gibt es mehrere Ansätze. Bei einer physikalischen Modellierung der Komponenten einer PV-Anlage sind genaue Daten des verwendeten PV-Moduls und des Wechselrichters notwendig. Der wichtigste Eingabeparameter ist die Globalstrahlung, die entweder von zumeist kostenpflichtigen Wetterdiensten bezogen oder durch herkömmliche Wetterparameter oder Zeitreihenanalysen abgeschätzt werden kann. Modelle der Zeitreihenanalyse oder der künstlichen neuronalen Netze können einen direkten Zusammenhang aus Eingabewerten zu der Leistung einer PV-Anlage herstellen. Der Vorteil dieser Modelle ist, dass keine spezifischen Anlageparameter notwendig sind und eventuelle Abschattungen auf das Modul berücksichtigt werden. Allerdings benötigen diese Modelle Zeitreihen zum Lernen, um eine bessere Prognose zu erreichen. Gleichzeitig können diese auch während sie eingesetzt werden trainiert werden, wodurch sie sich an veränderte Gegebenheiten anpassen können und so wiederum bessere Prognosen erstellen können.

4. Ausgewählte Prognosemodelle

In diesem Kapitel werden die für die Arbeit ausgewählten Modelle beschrieben und im Detail erklärt. Es wird sowohl ein physikalisches Modell, das detaillierte Informationen der verwendeten Komponenten erfordert, als auch ein künstliches neuronales Netz zur Prognose der PV-Leistung erstellt.

4.1 Physikalisches Modell

Das in dieser Arbeit realisierte physikalische Modell orientiert sich an dem von Bofinger und Heilscher in [BoHe06] veröffentlichte Modell. Es wird basierend auf der Vorhersage der Solarstrahlung die erwartete Leistung der PV-Anlage berechnet. Die Autoren verwenden die Wettervorhersageinformationen des Europäischen Zentrums für mittelfristige Wettervorhersagen ([ECMW13]). Diese grobgranularen Vorhersagen werden durch die statistische Methode **MOS** (Model Output Statistics) unter der Verwendung lokaler Wetterstationen und Statistiken so verfeinert, dass eine lokale Wetter- und Solarstrahlungsvorhersage getroffen werden kann. Zur Vorhersage der PV-Leistung muss für jeden Vorhersagezeitpunkt die **Sonnenposition** berechnet werden. Dazu verwenden die Autoren einen Algorithmus nach DIN 5034-2 ([Deut85]). Unter der Verwendung der Modelle von Reindl ([ReBD90]) und Klucher ([Kluc79]) wird die prognostizierte Solarstrahlung auf das PV-Modul berechnet. Das PV-Modul und der Wechselrichter werden nach den Modellen von Beyer et al. ([BBDH⁺04]) bzw. Schmidt und Sauer ([ScSa96]) abgebildet.

4.1.1 Berechnung der auf das PV-Modul treffende Solarstrahlung

Da das Modell von Bofinger und Heilscher die Globalstrahlung als Eingabeparameter benötigt, der verwendete Wetterdienst diesen aber nicht liefert, wird das **CR-Modell**¹ von Muneer und Gul ([MuGu00]) verwendet, um basierend auf der **Wolkenbedeckung** die Globalstrahlung abschätzen zu können. Das von Bofinger und Heilscher verwendete Reindl-Modell ist somit obsolet. Muneer und Gul beziehen sich auf eine Arbeit von Kasten und Czeplak ([KaCz80]), die die Beziehung von Globalstrahlung und Wolkenbedeckung zwischen den Jahren 1964 und 1973 in Hamburg analysiert haben. Kasten und Czeplak stellten den in Formel 4.1 gezeigten Zusammenhang bei wolkenfreiem Himmel fest. Die Globalstrahlung ist dabei nur vom Elevationswinkel γ der Sonne abhängig. Die Variablen A und B wurden per Regression ermittelt und sind Tabelle 4.1 zu entnehmen.

Bei der Validierung dieser Koeffizienten von Muneer und Gul für fünf Städten Großbritanniens zeigte sich ein zufriedenstellendes Ergebnis. Die für diese Städte zusätzlich ermittelten Koeffizienten brachten nur leicht verbesserte Ergebnisse hervor. Aus diesem Grund werden die für Hamburg ermittelten Koeffizienten auch in dieser Arbeit verwendet.

$$I_{GC} = A \sin(\gamma) - B \quad (4.1)$$

	Breitengrad, N	A	B	C	D
Hamburg	58.3	910	30	0.75	3.4
Stornoway	58.2	979	45	0.73	3.4
Aldergrove	54.6	956	34	0.70	3.1
Finningley	53.0	902	36	0.71	3.7
Aberporth	52.1	1024	54	0.71	4.2
London	51.5	948	49	0.71	3.4

Tabelle 4.1: Koeffizienten des CR-Modells.

Kasten und Czeplak haben des Weiteren festgestellt, dass das Verhältnis der Globalstrahlung bei wolkenbedecktem Himmel (I_G) zu wolkenfreiem Himmel (I_{GC}) unabhängig von der Sonnenhöhe (γ) ist (s. Formel 4.2). Die Wolkenbedeckung N wird in acht Achtel klassifiziert.

$$\frac{I_G}{I_{GC}} = 1 - C \left(\frac{N^D}{8} \right) \quad (4.2)$$

¹cloud-radiation-model

Das Verhältnis aus diffuser Strahlung (I_D) und Strahlung bei wolkenbedecktem Himmel (I_G) lässt sich durch Formel 4.3 beschreiben.

$$\frac{I_D}{I_G} = 0,3 + 0,7 \left(\frac{N}{8} \right) \quad (4.3)$$

Nach Multiplikation der rechten Seite von Formel 4.2 mit I_{GC} bzw. von Formel 4.3 mit I_G kann die Globalstrahlung bei wolkenbedecktem Himmel I_G und der diffuse Anteil der Globalstrahlung I_D berechnet werden. Der direkte Strahlungsanteil I_{dir} ergibt sich aus der Differenz von Global- und Diffusstrahlung.

$$I_{dir} = I_G - I_D$$

Nachdem nun der diffuse und direkte Strahlungsanteil auf die horizontale Fläche berechnet ist, muss als nächstes die Strahlung auf das geneigte PV-Modul berechnet werden. Dazu muss zunächst verdeutlicht werden welche Winkel und Definitionen im Folgenden verwendet werden (siehe Abbildung 4.1). Der Einfallswinkel Θ_{gen} beschreibt den Winkel zwischen einem Sonnenvektor s und dem Normalenvektor n des PV-Moduls. α_E beschreibt den Azimut- und γ_E den Neigungswinkel des PV-Moduls. α_E hat bei Südausrichtung den Wert 0° , bei Nordausrichtung den Wert 180° . γ_S ist der Elevationswinkel der Sonne, der als Winkel zwischen dem Mittelpunkt der Sonne und dem Horizont des Betrachters definiert wird (vgl. [Quas13]). Der Azimutwinkel der Sonne α_S gibt die Himmelsrichtung der Sonne an (siehe Tabelle 4.2).




Abbildung 4.1: Bestimmung des Sonneneinfallswinkels. [Quas13]

Zur Berechnung des Höhen- und Azimutwinkels der Sonne benutzen Bofinger und Heilscher einen Algorithmus nach DIN 5034-2 ([Deut85]). Quaschnig nennt in

Himmelsrichtung	Azimutwinkel
Nord	0°
Ost	90°
Süd	180°
West	270°

Tabelle 4.2: Azimutwinkel der Sonne.

[Quas13] weitere Algorithmen zur Sonnenstandsberechnung. Darunter den vom National Renewable Energy Laboratory entwickelten **SOLPOS**-Algorithmus, der nach Quaschnig eine höhere Genauigkeit hat und **kostenfrei** im Internet **erhältlich** ist ([MIDC00]). Als Eingabeparameter benötigt dieser die Geokoordinaten des Standorts, das Datum, die Uhrzeit und die Zeitverschiebung im Vergleich zur koordinierten Weltzeit UTC (Universal Time Coordinated).

Nach Quaschnig [Quas13] berechnet sich der Sonneneinfallswinkel Θ_{gen} auf das geneigte PV-Modul wie folgt:

$$\theta_{gen} = \arccos(-\cos \gamma_S \cdot \sin \gamma_E \cdot \cos(\alpha_S - \alpha_E) + \sin \gamma_S \cdot \cos \gamma_E)$$

γ_S ist der Sonnenelevationswinkel, γ_E der Neigungswinkel des PV-Moduls, α_S der Sonnenazimutwinkel und α_E der Azimutwinkel des Moduls.

Die auf das PV-Modul treffende Strahlung ist abhängig vom eben berechneten Einfallswinkel. Trifft die Strahlung im rechten Winkel auf das Modul, so ist die Bestrahlungsstärke am höchsten. Ist der Einfallswinkel dagegen sehr klein, im ungünstigsten Fall sogar null oder negativ, ist auch die Bestrahlung gering. Der direkte Strahlungsanteil auf die geneigte Fläche berechnet sich nach folgender Formel:

$$I_{dir,gen} = I_G \cdot \frac{\cos \theta_{gen}}{\sin \gamma_S}$$

Der direkte Strahlungsanteil auf die geneigte Fläche berechnet sich aus dem Produkt der Globalstrahlung I_G mit dem Quotient aus dem Kosinus des Einfallswinkels θ_{gen} und dem Sinus des Sonnenhöhenwinkels γ_S .

Zur Berechnung des diffusen Anteils auf die geneigte Fläche $I_{diff,gen}$ verwenden Boffinger und Heilscher das anisotrope Modell von Klucher ([Kluc79]). $I_{diff,gen}$ wird nach folgender Formel berechnet:

$$I_{diff,gen} = I_G \cdot \frac{1}{2} \cdot (1 + \cos \gamma_E) \cdot \left(1 + F + \sin^3 \frac{\gamma_E}{2}\right) \cdot \left(1 + F \cdot \cos^2 \theta_{gen} \cdot \cos^3 \gamma_S\right)$$

Der Parameter F ist die sog. Regulierungsfunktion, die die diffuse Strahlung I_D zur Globalstrahlung I_G ins Verhältnis setzt:

$$F = 1 - \left(\frac{I_D}{I_G} \right)^2$$

Bei der Berechnung der Bestrahlung auf die geneigte Fläche muss neben der direkten und diffusen Bestrahlung auch die vom Boden reflektierte Strahlung $I_{alb,gen}$ berechnet werden. Die reflektierte Strahlung ist dabei vom Untergrund und auch von der Jahreszeit abhängig. So reflektiert z. B. eine frische Schneedecke im Winter stärker als verwitterter Beton. $I_{alb,gen}$ berechnet sich wie folgt:

$$I_{alb,gen} = I_G \cdot A \cdot \frac{1}{2} \cdot (1 - \cos \gamma_E)$$

Der Albedo-Wert A hat den größten Einfluss auf die Genauigkeit der Berechnung.

Ist dieser Wert nicht bekannt, so wird in der Regel $A = 0,2$ angenommen. Tabelle 4.3 zeigt eine Auswahl an Albedo-Werten für unterschiedliche Untergründe.

Untergrund	Albedo A
Rasen (Juli, August)	0,25
Schotter	0,18
Beton, verwittert	0,20
Beton, sauber	0,30
Zement, sauber	0,55
Asphalt	0,15
Frische Schneedecke	0,80 bis 0,90

Tabelle 4.3: Eine Auswahl unterschiedlicher Albedo-Werte.

Die Gesamtstrahlung auf das PV-Modul I_{gen} entspricht der Summe aus $I_{dir,gen}$, $I_{diff,gen}$ und $I_{alb,gen}$:

$$I_{gen} = I_{dir,gen} + I_{diff,gen} + I_{alb,gen}$$

4.1.2 Simulation des Photovoltaikmoduls

Zur Simulation des PV-Moduls wird das von Beyer et al. ([BBDH⁺04]) vorgestellte Modell verwendet, das den Wirkungsgrad des Moduls im MPP-Bereich (η_{MPP}) in Abhängigkeit der Modultemperatur und der einfallenden Strahlung berechnet. Dazu wird das von Williams et al. in [WBHG⁺03] vorgestellte Modell, das den Wirkungsgrad bei einer konstanten Modultemperatur von 25°C berechnet, verwendet. Formel 4.4 zeigt diesen Zusammenhang, wobei die Variablen $a1$ bis $a3$ empirisch bestimmt werden müssen.

$$\eta_{MPP}(I_{gen}, 25^\circ C) = a1 + a2 \cdot I_{gen} + a3 \cdot \ln(I_{gen}) \quad (4.4)$$

Zur Bestimmung der Variablen $a1$ bis $a3$ sind Informationen über das PV-Modul notwendig, die häufig aus dem Datenblatt des PV-Moduls abgelesen werden können. Die Autoren empfehlen die Variablen mittels linearer Regression aus den folgenden Angaben zu bestimmen:

- MPP-Leistung unter Standardtestbedingungen.
- MPP-Leistung bei $25^\circ C$ Modultemperatur und zwei unterschiedlichen Strahlungswerten.
- MPP-Leistung bei einer Einstrahlung von 1000 W/m^2 und einer Modultemperatur ungleich $25^\circ C$.

Der Wirkungsgrad bei einer Modultemperatur ungleich $25^\circ C$ wird durch den in Formel 4.5 gezeigten Zusammenhang berechnet. T_M entspricht dabei der Modultemperatur, α dem Temperaturkoeffizient, der ebenfalls aus dem Datenblatt abgelesen werden kann.

$$\eta_{MPP}(I_{gen}, T_M) = \eta_{MPP}(I_{gen}, 25^\circ C) \cdot (1 + \alpha (T_M - 25^\circ C)) \quad (4.5)$$

Zur Bestimmung der Modultemperatur T_M verwenden Lorenz et al. in [LHKH⁺07] folgenden Zusammenhang von Umgebungstemperatur T_A , der Einstrahlung I_G und einem vom Installationsort des PV-Moduls abhängigen Koeffizienten γ :

$$T_M = T_A + \gamma \cdot I_G$$

Eine Auswahl an Werten für den Koeffizienten ist Tabelle 4.4 zu entnehmen. Der höhere Wert für die Dachintegration erklärt sich durch eine schlechtere Belüftung als bei einem freistehendem Aufbau, wodurch sich das Modul schneller erwärmt.

Art des Einbaus	γ
Dachintegration	$0.056 \frac{^\circ C m^2}{W}$
Freistehender Aufbau	$0.02 \frac{^\circ C m^2}{W}$

Tabelle 4.4: γ -Werte für ausgewählte Moduleinbauarten. [LSHH⁺11]

4.1.3 Simulation des Wechselrichters

Mit dem Modell von Schmidt und Sauer ([ScSa96]) wird der Wirkungsgradverlauf des Wechselrichters auf Basis eines physikalischen Verlustmodells bestimmt. Als Eingabeparameter benötigt das Modell den Wirkungsgrad η_{inv} des Wechselrichters für drei verschiedene Leistungspunkte. Dies könnten z. B. die Wirkungsgrade bei 10 %, 50 % und 100 % der Eingangsleistung sein, die dem Datenblatt zu entnehmen sind. Der Wirkungsgrad η_{inv} kann in Abhängigkeit der gegebenen Informationen aus der Ein- oder der Ausgangsleistung berechnet werden. Allgemein ist der Wirkungsgrad wie folgt definiert:

$$\eta_{inv} = \frac{p_{out}}{p_{in}} = \frac{p_{out}}{p_{out} + p_{loss}}$$

p_{in} , p_{out} und p_{loss} stehen für die Eingangs-, Ausgangs- und Verlustleistung. p_{loss} setzt sich wie folgt zusammen:

$$p_{loss} = p_{self} + v_{loss} \cdot p_{out} + r_{loss} \cdot p_{out}^2$$

p_{self} , v_{loss} und r_{loss} können als leistungsunabhängiger Verlust, als Spannungsverlust an Dioden und Transistoren bzw. als ohmsche Verlustwiderstände interpretiert werden. Aufgrund der Komplexität der Formeln zur Berechnung des Verlusts wird auf die Darstellung verzichtet und auf den Artikel von Schmidt und Sauer verwiesen. Abbildung 4.2 zeigt den typischen Verlauf eines aktuellen Wechselrichters.




Abbildung 4.2: Wirkungsgrad des Wechselrichters SMA Sunny Boy 3000TL-20 basierend auf der Ausgangsleistung. [SMA10]

4.1.4 Berechnung der resultierenden PV-Leistung

Die resultierende Leistung der Photovoltaikanlage berechnet sich nach folgender Formel:

$$P_{PV} = I_{gen} \cdot A_{panel} \cdot \eta_{MPP} \cdot \eta_{inv}$$

A_{panel} entspricht der Fläche der PV-Anlage in m^2 .

4.2 Künstliches Neuronales Netz

Die Realisierung eines Vorhersagemodells, das keine genaue Spezifikation der Photovoltaikanlage benötigt, wird mit einem KNN realisiert. Künstliche neuronale Netze sind ein Teilzweig der künstlichen Intelligenz. Ein KNN ist eine vereinfachte Abbildung des menschlichen zentralen Nervensystems, das durch die Verbindung neuronaler Prozessorelemente auf Eingaben reagieren, lernen und sich so der Einsatzumgebung anpassen kann. Ein KNN besteht aus einer Eingabeschicht, einer Ausgabeschicht und kann beliebig viele verborgene Schichten enthalten. Die Schichten wiederum können beliebig viele Eingabe-, Ausgabe bzw. verborgene Neuronen enthalten. Eingabeneuronen empfangen Reize aus der Umgebungen und sind der Eintrittspunkt in das KNN. Ausgabeneuronen entsprechen der Ausgabe des Netzes. Die Neuronen können, abhängig vom Netztyp, beliebig miteinander verbunden sein und stellen Berechnung an, deren Ergebnis zur weiteren Verarbeitung an das nächste

Neuron übermittelt wird. Zusätzlich müssen die Zellen charakterisiert werden, d. h. es muss definiert sein, wie die Eingabesignale an einem Neuron kombiniert werden und welche Transformation das Neuron damit durchführt (sog. Aktivierungsfunktion). Der Signalfluss innerhalb des Netzes wird mit Verbindungen zwischen den Neuronen realisiert, die unterschiedlich gewichtet sind. Eine positive Gewichtung bedeutet, dass ein anregender Einfluss, eine negative Gewichtung, dass ein hemmender Einfluss vorliegt. KNNs können als Graphen abgebildet werden, wobei die Knoten den Neuronen und die Kanten den Verbindungen zwischen den Neuronen entsprechen. Mittels Trainings- oder Lernalgorithmen können die Gewichtungen basierend auf Trainingsdatensätze bestimmt werden. Abbildung 4.3 zeigt ein einfaches KNN mit jeweils einer Eingabe- und Ausgabeschicht die jeweils aus drei Neuronen bestehen. (Vgl. [Patt97])




Abbildung 4.3: Ein einfaches KNN.

4.2.1 Lernalgorithmus - Backpropagation

Zur Bestimmung der Gewichtungen zwischen den Neuronen wird das Lernverfahren Backpropagation (BP) eingesetzt. BP gehört in die Kategorie der überwachten Lernverfahren. Dies bedeutet, dass beim Training für alle Eingabewerte auch der geforderte Ausgabewert bekannt sein muss. Während des Trainings wird pro Eingabevektor der Ausgabevektor der Ausgabeschicht berechnet. Diese Ausgabe wird dann mit der erwarteten, idealen Ausgabe verglichen und ein Fehlerwert ermittelt. Der Fehlerwert wird nun rückwärts Schicht für Schicht, mittels Feedback-Verbindungen, zur Anpassung der Gewichtungen verwendet. Dies wird für jeden Datensatz der Trainingsmenge ausgeführt, sodass der gesamte Ausgabefehler gegen ein Minimum konvergiert. BP kann auf allen mehrschichtigen Netzen angewendet werden, erfordert aber differenzierbare Aktivierungsfunktionen die einen Grenzwert besitzen. (Vgl. [Patt97])

4.2.2 Rekursives Neuronales Netz (RNN)

Im Rahmen dieser Arbeit wird das KNN als ein rekursives neuronales Netz realisiert. Yona et al. haben in [YSSF⁺08] die Leistungsfähigkeit zur Globalstrahlungsprognose von drei KNNs unterschiedlichen Typs auf Basis der Umgebungstemperatur verglichen. Das RNN liefert im Vergleich zu einem Feedforwardnetz und einem radial Basisfunktionsnetz die besten Ergebnisse. Als Aktivierungsfunktion wurde eine Sigmoidfunktion (siehe Abbildung 4.4) und BP als Trainingsalgorithmus verwendet. Aufgrund der gewählten Aktivierungsfunktion ist es notwendig, dass keine negativen Werte in das Netz eingegeben werden. Die Eingabeparameter müssen deshalb auf $[0..1]$ normalisiert werden (siehe Formel 4.6). Den Zusammenhang zur Denormalisierung zeigt Formel 4.7.




Abbildung 4.4: Abbildung einer Sigmoidfunktion.

$$f(x) = \frac{(x - d_L) \cdot (n_H - n_L)}{(d_H - d_L)} + n_L \quad (4.6)$$

$$f(x) = \frac{(d_L - d_H) \cdot x - (n_H \cdot d_L) + d_H \cdot n_L}{(n_L - n_H)} \quad (4.7)$$

Die Variablen d_L und d_H entsprechen dem kleinsten bzw. größtem vorkommenden Wert in der Datenmenge, n_L und n_H stehen dagegen für den unteren und oberen Rand der Normalisierung.

Das RNN entspricht im Detail dem von Elman in [Elma91] vorgestellten KNN. Dieses zeichnet sich dadurch aus, dass die Ausgaben der verborgenen Schicht als Feedback über eine sog. Kontextschicht an sich selbst weitergegeben werden. Die Gewichtungen

zwischen der verborgenen Schicht und der Kontextschicht sind konstant und werden während des Trainings nicht verändert. Abbildung 4.5 zeigt die Architektur eines solchen Elman-RNNs.

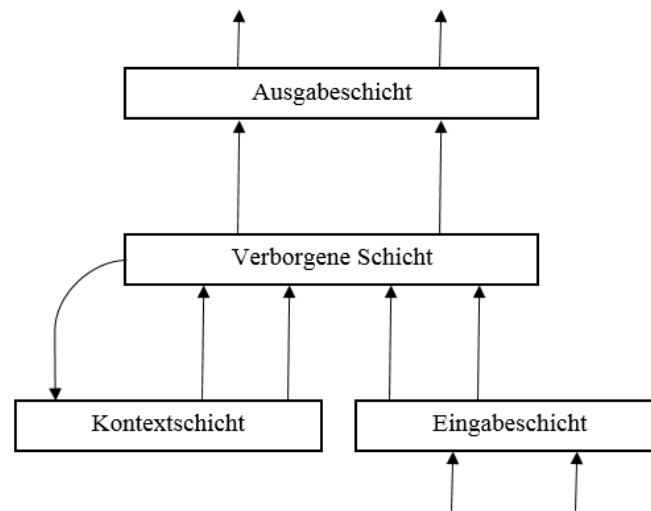


Abbildung 4.5: Die Architektur eines einfachen Elman-RNN. (nach [Patt97])

5. Implementierung

Im folgenden Kapitel werden die im Rahmen der Arbeit entwickelten Programme vorgestellt. Es wurden fünf Java-Programme implementiert, die verschiedene Teilaufgaben übernehmen und in regelmäßigen Zeitintervallen ausgeführt werden. In Unixartigen Betriebssystemen steht ein sogenannter Cron-Daemon zur Verfügung, der die zeitbasierte Ausführung von sich wiederholenden Aufgaben (sog. **Cron-jobs**) ermöglicht. Zur Konfiguration der Java-Anwendungen existiert eine zentrale Properties-Datei, in der die Einstellungen für alle implementierten Anwendungen vorgenommen werden. In Anhang A ist die Properties-Datei abgebildet. Als zentraler Datenspeicher wird eine **SQLite-Datenbank** verwendet. Alle Programme laufen auf dem Raspberry Pi.

5.1 Aufbau der Datenbasis

Die Datenbasis zur PV-Leistungsvorhersage wird durch die Programme *SMAspot*, *csv2sqlite*, *requestWeather*, *requestWeatherForecast* und *fusionPvWeather* aufgebaut. Nachfolgend werden die einzelnen Programme im Detail erklärt.

5.1.1 Abrufen/Speichern der PV-Leistung

Die Leistungsdaten werden von dem SMA-Wechselrichter mittels *SMAspot* abgerufen. Das Programm muss nach erfolgreichem Kompilieren mit dem Wechselrichter über Bluetooth verbunden werden. Dazu sind die folgenden Einstellungen in der Konfigurationsdatei vorzunehmen:

- Obligatorisch

Bluetooth-Adresse des Wechselrichters

Bluetooth-Passwort des Wechselrichters

Geokoordinaten

Export als CSV-Dateien

Exportpfad

- Optional

Datenupload auf pvoutput.org

Das Tool wird über ein Shell-Script gestartet, das als Cronjob alle fünf Minuten ausgeführt wird. Die verschiedenen SMA-Wechselrichter halten die historischen PV-Leistungsdaten unterschiedlich lange im internen Speicher. Beim verwendeten Sunny Boy 3000TL-20 sind die täglichen Leistungswerte der vergangenen 60 Tage verfügbar. Diese werden beim ersten Start von *SMAspot* abgerufen und als CSV-Dateien gespeichert. In der CSV-Datei wird der Zeitpunkt der Messung, die erzeugte kumulierte Energie und die Leistung ausgegeben (siehe Listing 5.1).

```
yyyy-MM-dd HH:mm:ss;kWh;kW
2013-09-13 15:15:00;5810,398;1,128
2013-09-13 15:20:00;5810,487;1,068
2013-09-13 15:25:00;5810,570;0,996
2013-09-13 15:30:00;5810,657;1,044
2013-09-13 15:35:00;5810,745;1,056
2013-09-13 15:40:00;5810,841;1,152
2013-09-13 15:45:00;5810,927;1,032
```

Listing 5.1: Auszug der CSV-Exportdatei des SMA-Wechselrichters.

Die CSV-Dateien werden durch *csv2sqlite* in die Datenbanktabelle *pv_data* (siehe Abbildung B.1) geschrieben. Da die Wetterdaten in stündlicher Auflösung vorliegen, wird in einem weiteren Schritt die Energie pro Stunde aus *pv_data* berechnet und in die Tabelle *pv_energy* (siehe Abbildung B.2) gespeichert. Das Programm *csv2sqlite* wird über einen Cronjob alle 24 Stunden um Mitternacht ausgeführt.

5.1.2 Abrufen/Speichern aktueller Wetterinformationen

Aktuelle Wetterinformationen werden mit dem Programm *requestWeather* abgerufen und gespeichert. Wie in Kapitel 2.4.2 geschrieben wird dazu der Wetterdienst Open Weather Map verwendet. Zur Kommunikation mit dem Wetterdienst wird die quelloffene Java-Bibliothek *owmClient* [Tava13] verwendet. Diese musste aufgrund von Änderungen am Datenformat von Open Weather Map an die aktuelle Version angepasst werden. In der Properties-Datei müssen die Postleitzahl, der Ländercode

(z. B. „DE“ für Deutschland) und die von **Open Weather Map** generierte App-ID eingetragen werden. Folgende Wetterparameter werden abgerufen:

- Temperatur ($^{\circ}C$)
- Maximale und minimale Temperatur ($^{\circ}C$)
- Luftdruck (hPa)
- Relative Luftfeuchtigkeit (%)
- Wolkenbedeckung (%)
- Niederschlag (mm^3/m^2)
- Windgeschwindigkeit (m/s)
- Windrichtung ($^{\circ}$)

Die empfangenen Wetterdaten werden in die Tabelle *current_weather* geschrieben (siehe Abbildung B.4). Das aktuelle Wetter wird via Cronjob zu jeder vollen Stunde abgerufen und gespeichert.

5.1.3 Abrufen/Speichern der Wettervorhersage

Zum Abrufen der Wettervorhersage wurde das Programm *requestWeatherForecast* implementiert. In der Properties-Datei sind die gleichen Einstellungen wie in Kapitel 5.1.2 vorzunehmen. Es stehen dieselben Wetterparameter wie bei den aktuellen Wetterinformationen zur Verfügung. **Die zeitliche Auflösung der Daten beträgt drei Stunden, der Prognosehorizont sieben Tage.** Über einen Cronjob wird die Wettervorhersage zu jeder vollen Stunde abgerufen und in der Tabelle *weather_forecast* gespeichert (siehe Abbildung B.5).

5.1.4 Fusionierung der PV-Leistungs- und Wetterinformationen

Das Programm *fusionPvWeather* fusioniert die auf volle Stunden abgebildeten PV-Leistungsdaten aus *p_v_energy* und die Wetterinformationen aus *current_weather*, sodass zu jedem PV-Leistungsdatum das dazugehörige Wetter vorhanden ist. Die Fusionierung basiert auf der Anpassung der jeweiligen Zeitstempel. Zuvor findet eine Vollständigkeitsprüfung der Wetterinformationen in zwei Schritten statt. Im ersten Schritt werden fehlende Wetterinformationen, über die Möglichkeit historische Wetterdaten abzufragen, ergänzt. Dabei werden die vorhandenen PV-Datenintervalle

mit den Wetterdaten abgeglichen, die Zeitpunkte fehlender Wetterinformationen gespeichert und mit historischen Wetterdaten aufgefüllt. Wenn für diese Zeitpunkte keine historischen Wetterdaten zur Verfügung stehen, findet in einem zweiten Schritt eine Ergänzung dieser Daten mittels linearer Abschätzung statt. Dabei werden die Lücken in der *current_weather*-Tabelle gesucht, die zusammenhängend nicht länger als zwei Stunden sein dürfen.

Neben den Wetterdaten werden für jeden Zeitpunkt die Informationen des *SOLPOS*-Algorithmus berechnet. Dazu wurde der in C programmierte, quelloffene Programmcode in Java übersetzt und als Bibliothek in *fusionPvWeather* eingebunden. Zur Berechnung des Azimutwinkels, des Höhenwinkels und der extraterrestrischen Strahlung müssen die Geokoordinaten des Standortes, der Zeitpunkt und die Zeitverschiebung im Vergleich zur koordinierten Weltzeit UTC (Universal Time Coordinated) angegeben werden. Die Ergebnisse der *SOLPOS*-Berechnung werden in der Tabelle *solpos* (siehe Anhang B.3) gespeichert. *FusionPvWeather* wird als Cronjob jede Nacht nach dem Import der PV-Leistungsdaten ausgeführt.

5.2 PV-Leistungsprognose

Zur Leistungsprognose der PV-Anlage sind zwei Verfahren implementiert. Zum einen das in Kapitel 4.1 beschriebene physikalische Verfahren und zum anderen das in Kapitel 4.2 erläuterte künstliche neuronale Netz. Die Prognose wird durch beide Modelle berechnet und sowohl in der Tabelle *power_forecast* (siehe Anhang B.6), als auch in einer CSV-Datei gespeichert. Der Exportpfad der CSV-Datei muss in der Properties-Datei festgelegt werden. Die Prognose wird nach der Ausführung der Programme zum Aufbau der Datenbasis als Cronjob ausgeführt.

Zur Berechnung der Prognose wird die Wettervorhersage für den nächsten Tag verwendet.

5.2.1 Physikalisches Modell

Das physikalische Modell ist im Detail in Kapitel 4.1 beschrieben worden. Die notwendigen Eingabeparameter müssen in der Properties-Datei festgelegt werden. Folgende Parameter müssen für das PV-Modul angegeben werden:

- Azimutwinkel des Moduls ($^{\circ}$)
- Inklinationswinkel ($^{\circ}$)
- Fläche (m^2)
- Maximalleistung (W)

- Installationskoeffizient
- Temperaturkoeffizient ($\%/^{\circ}C$)
- Modellparameter $a1$, $a2$, $a3$ (siehe Kapitel 4.1)

Der Azimutwinkel des Moduls gibt die Himmelsrichtung an, in die die Anlage ausgerichtet ist. 0° entspricht einer Ausrichtung in südlicher, 180° in nördlicher Richtung. Die Neigung des Moduls wird als Inklinationswinkel angegeben. Zudem müssen die Fläche der Anlage in m^2 und die maximale Leistung in *Watt* angegeben werden. Der Installationskoeffizient ist abhängig von dem Installationsstandort. Es wird dabei u. a. zwischen einer dachnahen und freistehenden Installation unterschieden. Der Temperaturkoeffizient gibt den Wirkungsgradverlust pro zusätzlichem $^{\circ}C$ über $25^{\circ}C$ an. Die Modellparameter $a1$ bis $a3$ können z. B. durch lineare Regression, wie in Kapitel 4.1 beschrieben, bestimmt werden.

Für das im Rahmen dieser Arbeit verwendete PV-Modul ergeben sich folgende Parameterwerte, die vom Eigentümer der Anlage zur Verfügung gestellt werden.

- Azimutwinkel: 65°
- Inklinationswinkel: 60°
- Fläche: $23 m^2$
- Maximalleistung: $3510 W$
- Installationskoeffizient: 0,0568 (dachnahe Installation)
- Temperaturkoeffizient: $-0,0047$
- $a1$: 0,2004
- $a2$: $-0,0001398$
- $a3$: 0,1351

Die Modellparameter $a1$ bis $a3$ können aus Mangel an Informationen im Datenblatt nicht berechnet werden. Deshalb wurden die Parameter aus der Arbeit von Linder (vgl. [Lind12]) verwendet.

Zur Modellierung des Wechselrichters sind folgende Parameter in der Properties-Datei anzugeben:

- Maximale Eingangsleistung DC (W)

- Maximale Ausgangsleistung AC (W)
- Wirkungsgrad bei 10% der Maximalleistung (η_{10})
- Wirkungsgrad bei 50% der Maximalleistung (η_{50})
- Wirkungsgrad bei 100% der Maximalleistung (η_{100})
- Maximaler Wirkungsgrad η_{nom}
- Wirkungsgradbezug

Die geforderten Daten können i. d. R. dem Datenblatt entnommen werden. Die Wirkungsgrade η_{10} , η_{50} und η_{100} können sowohl auf die Eingangs-, als auch auf die Ausgangsleistung bezogen sein. Entsprechend muss der Parameter *Wirkungsgradbezug* gesetzt werden. Für den verwendeten Wechselrichter ergeben sich folgende Parameter, die aus dem Datenblatt [SMA10] abgelesen wurden:

- Maximale Ausgangsleistung AC: 3000 W
- Maximale Eingangsleistung DC: 3200 W
- η_{10} : 0,933
- η_{50} : 0,969
- η_{100} : 0,97
- η_{nom} : 0,97
- Wirkungsgradbezug: Ausgangsleistung

Die Berechnung der Leistung folgt den in Kapitel 4.1 beschriebenen Schritten, die hier nochmal kurz zusammengefasst werden. Basierend auf der Wolkenbedeckung wird die auf die Erde horizontal treffende Global- und Diffusstrahlung nach Gul et al. ([GuMK98]) berechnet. Mit dem Modell von Klucher ([Kluc79]) wird der Anteil der direkten, diffusen und der Albedostrahlung bestimmt. Die Summe daraus entspricht der Solarstrahlung die auf das PV-Modul fällt. Auf Grundlage der Parameter des PV-Moduls, der Umgebungstemperatur und der eben bestimmten Strahlung wird der Wirkungsgrad des Moduls berechnet. Das Produkt aus Strahlung, Wirkungsgrad und Anlagenfläche entspricht der Ausgangsleistung des PV-Moduls. Im nächsten Schritt wird der Wirkungsgrad des Wechselrichters mit der eben berechneten Ausgangsleistung des PV-Moduls bestimmt. Das Produkt aus Strahlung, PV- und Wechselrichterwirkungsgrad und Anlagenfläche ergibt Anlagenleistung des Modells für den entsprechenden Zeitpunkt in W .

5.2.2 Künstliches Neuronales Netz (KNN)

Zur Implementierung des KNN wurde das **quelloffene Framework für maschinelles Lernen Encog** ([Heat13]) verwendet. Das KNN wurde als rekursives neuronales Netz mit $1..x$ Eingabeneuronen (Wetterparameter), einer verborgenen Schicht mit $1..20$ verborgenen Neuronen und einem Ausgabeneuron (Leistung) entworfen. Als Trainingsalgorithmus wird Backpropagation eingesetzt.

Bei der ersten Prognoserechnung findet ein **Training des Netzes mit allen vorhandenen PV- und Wetterdaten statt, sodass das Netz einmalig initialisiert ist.** Das Netz wird nach jedem Training persistent gespeichert. Bei jeder weiteren Prognose wird ein Training mit den am Vortag aufgezeichneten Daten ausgeführt. Wie in der Evaluation in Kapitel 6.3 gezeigt wird, ergeben Vorhersagen mit folgenden Eingabeparameter und drei verborgenen Neuronen das beste Ergebnis:

- Azimutwinkel der Sonne
- Elevationswinkel der Sonne
- Extraterrestrische Globalstrahlung (W/m^2)
- Luftfeuchtigkeit (%)
- Temperatur ($^{\circ}C$)

Zum Training und zur Berechnung der Prognose werden die Ein- und Ausgabeparameter auf $[0..1]$ normalisiert.

5.3 Zusammenfassung

Die im Rahmen dieser Arbeit implementierten Programme speichern die vom Wechselrichter vorgehaltenen historischen Energie- und Leistungsdaten in einer SQLite-Datenbank. Die dazugehörigen Wetterdaten werden über den kostenlosen Wetterdienst Open Weather Map bezogen und ebenfalls in der Datenbank gespeichert. Die so gewonnenen Daten werden auf Vollständigkeit geprüft und können durch historischen Wetterdaten und linearer Abschätzung ergänzt werden. Der *SOLPOS*-Algorithmus berechnet sowohl den Höhen- und Azimutwinkel der Sonne als auch die extraterrestrische Globalstrahlung und fügt sie der Datenbank hinzu. Die Leistungsprognose der PV-Anlage wird sowohl durch ein physikalisches Modell, als auch durch ein KNN erzeugt. Das physikalische Modell benötigt detaillierte Informationen aus dem Datenblatt des verwendeten PV-Moduls und Wechselrichters. Die damit prognostizierte Leistung ist von der Wolkenbedeckung und der Umgebungstemperatur abhängig. Das KNN ist vom Typ eines rekursiven **neuronalen Netzes.**

Es ist **vierschichtig** mit einer Eingabe-, Ausgabe-, Kontext- und einer verborgenen Schicht. Es wurden KNNs unterschiedlicher Anzahl und Kombinationen von Eingabeneuronen und verborgenen Neuronen getestet. Das optimale KNN besteht aus fünf Eingabeneuronen, drei verborgenen Neuronen und einem Ausgabeneuron. Die optimalen Eingabeparameter sind: **Sonnenazimut, Sonnenhöhe, extraterrestrische Globalstrahlung, Luftfeuchtigkeit und Temperatur**. Die Prognose wird für den nächsten Tag erstellt und sowohl als CSV-Datei exportiert, als auch in der SQLite-Datenbank gespeichert.

6. Evaluierung

In diesem Kapitel werden die implementierten Modelle und deren Bestandteile evaluiert. Dazu stehen PV-Leistungs- und Wetterdaten vom 30.05.2013 bis zum 14.09.2013 in stündlicher Auflösung für eine PV-Anlage in Gleidingen¹ zur Verfügung. Dies entspricht 2494 vollständigen Datensätzen. Zur Bestimmung der Genauigkeit des Modells in Abhängigkeit von Wettervorhersageinformationen steht ein kleinerer Datensatz zur Verfügung. Dieser umfasst 130 Datensätze in dreistündiger Auflösung in dem Zeitraum vom 29.08.2013 bis zum 14.09.2013.

Basierend auf den Daten vom 30.05.2013 bis zum 14.09.2013 wurde der Korrelationskoeffizient r für alle vorhandenen Eingabeparameter in Bezug auf die resultierende PV-Leistung ermittelt. Der **Korrelationskoeffizient** gibt die Stärke des linearen Zusammenhangs zwischen zwei Merkmalen an, die intervall- oder nominalskaliert sind und berechnet sich aus dem Quotienten der Kovarianz und dem Produkt der Standardabweichungen beider Merkmale.

$$r = \frac{1}{N} \cdot \frac{\sum_{i=1}^N (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sqrt{\sum_{i=1}^N (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Die Variablen x bzw. y stehen für die jeweilige Merkmalsausprägung, \bar{x} und \bar{y} für deren Mittelwerte, N entspricht der Grundmenge. Der Korrelationskoeffizient nimmt einen Wert zwischen -1 und $+1$ an. Bei $+1/-1$ liegt ein vollständiger positiver/negativer linearer Zusammenhang zwischen den beiden Merkmalen vor. Null bedeutet, dass kein linearer Zusammenhang besteht. In Tabelle 6.1 ist der Korrelationskoeffizient zwischen den im Folgenden verwendeten Eingabemerkmalen und

¹Niedersachsen, in der Nähe von Hannover. Die PV-Anlage hat bei einer Modulfläche von 23 m^2 eine Peakleistung von 3510 W_p .

der daraus resultierenden PV-Leistung aufgezeigt. Die extraterrestrische Strahlung liefert den stärksten linearen Zusammenhang, gefolgt von der Sonnenhöhe. Ein mittlerer linearer Zusammenhang ist bei der Temperatur zu sehen, einen nur schwach linearen Zusammenhang bei der Windgeschwindigkeit, dem Luftdruck und dem Azimut der Sonne. Auffällig sind vor allem die negativen Korrelationskoeffizienten bei Niederschlag, Wolkenbedeckung und relativer Luftfeuchtigkeit. Diese haben einen negativen Einfluss auf die Leistung der PV-Anlage, wobei die relative Luftfeuchtigkeit am stärksten und der Niederschlag am schwächsten mit der Leistung negativ korreliert. Hammer et al. behaupten in [HHLL99], dass die Wolken den stärksten Einfluss auf die Globalstrahlung haben. Deshalb wäre zu erwarten gewesen, dass dieser Wert die größte negative Korrelation aufzeigt. Dies könnte dadurch erklärt werden, dass die relative Luftfeuchtigkeit, im Gegensatz zur Niederschlagsmenge oder der Wolkenbedeckung, häufig auch von privaten Messstationen aufgezeichnet wird und somit näher am Anlagenstandort gemessen wird.

Eingabemerkmal	r
Temperatur	0,5025
Rel. Luftfeuchtigkeit	-0,4990
Luftdruck	0,0859
Windgeschwindigkeit	0,1662
Wolkenbedeckung	-0,0310
Niederschlag	-0,0094
Sonnenazimut	0,0981
Sonnenhöhe	0,7817
Extraterrestrische Globalstrahlung	0,7885

Tabelle 6.1: Korrelationskoeffizienten der Eingabemerkmale.

6.1 Evaluationskriterien

Zur Evaluierung der implementierten Modelle werden drei Kriterien verwendet, mit denen die Vorhersagegenauigkeit bewertet wird.

Als **Hauptkriterium** wird die Quadratwurzel des mittleren quadratischen Fehlers (**RMSE**, root mean squar error) verwendet:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^N (p_{prognose} - p_{gemessen})^2}$$

Dieser berechnet die quadratische Differenz aus vorhergesagtem ($p_{prognose}$) und tatsächlich gemessenem ($p_{gemessen}$) Wert. Die Variable N gibt die Anzahl der untersuchten Datenpaare an. Durch die Verwendung des RMSE werden größere Abweichungen

stärker gewichtet als kleine.

Als zusätzliches Maß, das Abweichungen unterschiedlicher Größenordnung gleich bewertet, wird die mittlere absolute Abweichung (**MAE**, mean absolute error) verwendet:

$$MAE = \frac{1}{N} \sum_{i=1}^N |p_{prognose} - p_{gemessen}|$$

Um Aussagen bzgl. einer **Über- oder Unterschätzung** treffen zu können, wird der Durchschnitt der Abweichungen bestimmt (**BIAS**):

$$BIAS = \frac{1}{N} \sum_{i=1}^N (p_{prognose} - p_{gemessen})$$

Nimmt der *BIAS* einen negativen Wert an, so liegt eine Unterschätzung vor und bei positivem *BIAS* eine Überschätzung. Der Nachteil des *BIAS* ist, dass gleiche Fehler unterschiedlichen Vorzeichens sich gegenseitig aufheben können.

Zur Bestimmung der jeweiligen relativen Fehler in Prozent wird der errechnete Fehler ins Verhältnis zu der Peak-Leistung der PV-Anlage gesetzt. Die Peak-Leistung der in dieser Arbeit verwendeten PV-Anlage ist $3510 W_p$.

In der Literatur werden bei der Auswertung der Modelle unterschiedliche Ansätze zur Fehlerbestimmung bezüglich der verwendeten Daten gewählt. Manche Autoren beziehen die Daten, bei denen die gemessene Leistung Null ist, mit ein, manche schließen diese aus. Im Folgenden werden, wenn möglich, beide Werte angegeben, wobei $p_{gemessen} \geq 0$ Nullwerte mit einbezieht und $p_{gemessen} > 0$ diese ausschließt. Bei ausgeschlossenen Nullwerten stehen noch 1581 Datensätze zur Verfügung. Dies soll einer besseren Vergleichbarkeit mit anderen Arbeiten dienen.

Für alle genannten Fehlermaße gilt: **Je kleiner der Fehler, desto besser ist das Modell.**

6.2 Physikalisches Modell

In Tabelle 6.2 sind die absoluten und relativen Fehler für den Vergleich zwischen der Prognose des physikalischen Modells bei gemessenen Wetterdaten und der tatsächlich gemessenen Leistung vom 30.05.2013 bis 14.09.2013, sowohl mit Berücksichtigung der gemessenen Nullwerte, als auch ohne, zu sehen.

	RMSE	MAE	BIAS	rRMSE (%)	rMAE (%)	rBIAS (%)
$p_{gemessen} \geq 0$	508,93	279,44	-82,66	14,50 %	7,96 %	-2,35 %
$p_{gemessen} > 0$	637,29	439,57	-131,64	18,16 %	12,52 %	-3,75 %

Tabelle 6.2: Fehler des physikalischen Modells für den Zeitraum vom 30.05.2013 bis 14.09.2013 unter Verwendung gemessener Wetterinformationen.

Wie bereits oben erwähnt, unterscheiden sich die Fehlerwerte bei $p_{gemessen} \geq 0$ und $p_{gemessen} > 0$. Weil in der Nacht keine Differenzen zwischen gemessenen und

berechneten Werten auftreten, sind die $p_{\text{gemessen}} \geq 0$ Fehler kleiner. Das Modell liefert eine gute Genauigkeit bei einem $rRMSE$ von 18,16 % und einem $rMAE$ von 12,52 %, wobei die tatsächliche Leistung durchschnittlich mit einem $rBIAS$ von -3,75 % unterschätzt wird. In Abbildung 6.1 ist eine solche Vorhersage durch das Modell beispielhaft für den 16. und 17. Aug. 2013 zu sehen. Auf der x-Achse ist die Uhrzeit in Stunden, auf der y-Achse die Ausgangsleistung in Watt angegeben. Es ist zu sehen, dass am ersten Tag die Leistung zwischen neun und 15 Uhr vom Modell unterschätzt, in den Abendstunden aber überschätzt wird. Am zweiten Tag ist die Unterschätzung noch deutlicher zu sehen, da lediglich zwischen 14 und 16 Uhr eine Überschätzung vorliegt. Auffällig ist, dass zwischen sechs und neun aber auch zwischen 18 und 21 Uhr das Modell eine Leistungsprognose von 0 W ausgibt, obwohl zu diesem Zeitpunkt von der Anlage Strom erzeugt wird.

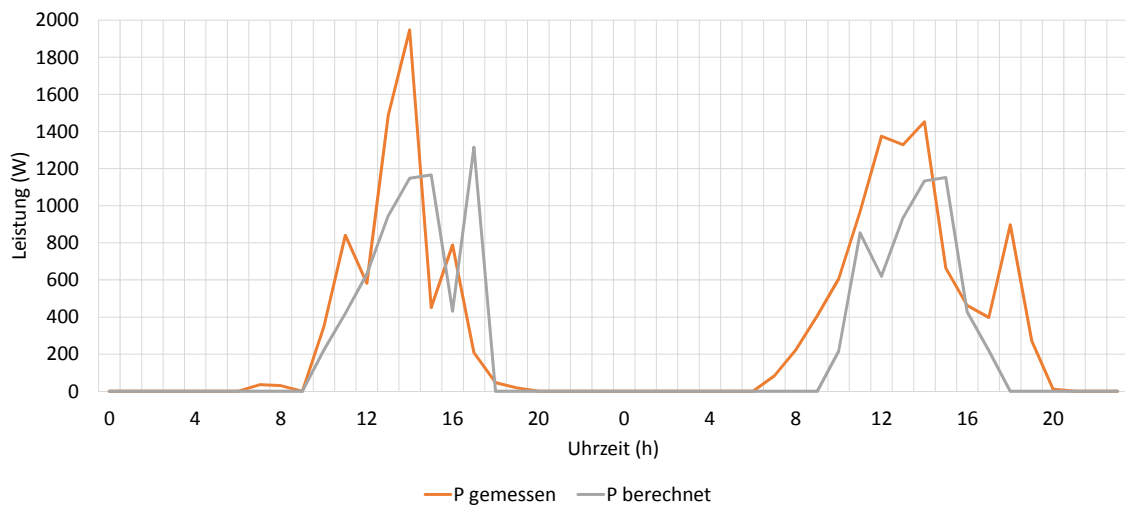


Abbildung 6.1: Vergleich der Berechnung des physikalischen Modells mit den gemessenen Werten.

Dies kann verschiedene Ursachen haben. Zum einen kann die auf das PV-Modul berechnete Globalstrahlung nicht richtig sein, zum anderen kann auch die Strahlung zu schwach sein, sodass das PV-Modul diese nicht in Strom umwandelt.

Abbildung 6.2 zeigt den berechneten, zeitlichen Verlauf für die auf das PV-Modul treffende Solarstrahlung. Es ist zu sehen, dass am zweiten Tag zwischen sechs und neun Uhr, aber auch zwischen 18 und 21 Uhr, die Solarstrahlung von maximal ca. 230 W/m^2 auf die PV-Anlage trifft. Mit dieser Strahlung kann nun der Wirkungsgrad des PV-Moduls berechnet werden.

Abbildung 6.3 zeigt den Wirkungsgrad in Abhängigkeit der eintreffenden Solarstrahlung. Die Modultemperatur ist konstant bei 25°C . Es sei an dieser Stelle nochmals darauf hingewiesen, dass nicht alle zur Bestimmung der Modellparameter notwen-

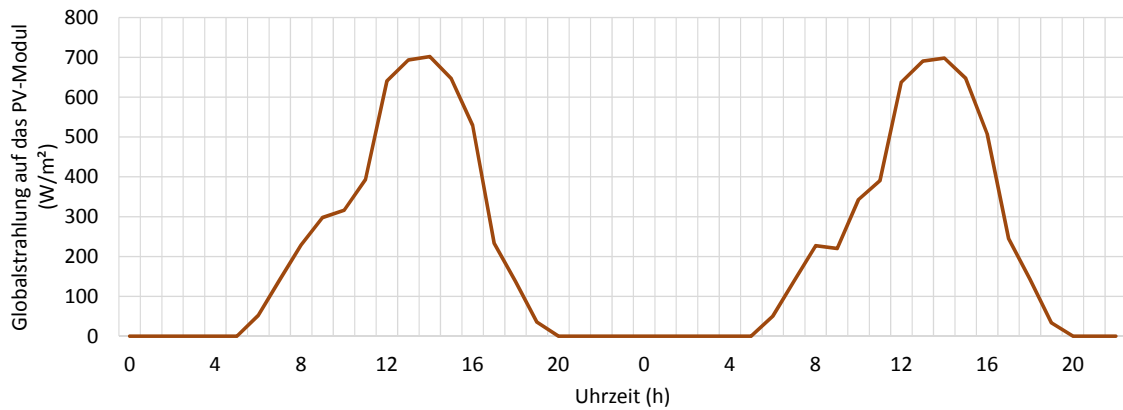


Abbildung 6.2: Zeitlicher Verlauf der auf das PV-Modul treffenden Solarstrahlung.

digen Daten aus dem Datenblatt zu entnehmen waren und deshalb auf die Parameter eines anderen PV-Moduls zurückgegriffen werden mussten. Bei dieser Kurve fällt auf, dass der Wirkungsgrad bis zu einer Einstrahlungsstärke von 226 W/m^2 bei $\eta = 0$ liegt. Die vom Modell verwendete Wirkungsgradlinie für den Wechselrichter ist in Abbildung 6.4 zu sehen. Zur Bestimmung des Wirkungsgradverlaufs konnten die notwendigen Parameter dem Datenblatt entnommen werden, weshalb die dargestellte Linie eine gute Schätzung des tatsächlichen Wirkungsgradverlaufs ist (siehe Abbildung 4.2).

Die Unterschätzung des Modells bei Einstrahlungswerten kleiner als 226 W/m^2 kann durch die Modellierung des PV-Moduls erklärt werden.




Abbildung 6.3: Der vom Modell berechnete Wirkungsgradverlauf des PV-Moduls in Abhängigkeit der Solarstrahlung.




Abbildung 6.4: Der vom Modell berechnete Wirkungsgradverlauf des Wechselrichters in Abhängigkeit von der Ausgangsleistung.

Im Folgenden soll die Genauigkeit des Modells basierend auf Wettervorhersagedaten bestimmt werden. Dazu stehen ca. 120 Datensätze vom 29.08.2013 bis zum 13.09.2013 zur Verfügung. Die verwendeten Wetterprognosen haben einen Vorhersagehorizont von zwölf Stunden, um die Datengrundlage nicht noch stärker zu verringern. Die Analyse ist aufgrund der geringen Datengrundlage mit Vorsicht zu interpretieren, da nur wenige verschiedene Wetterverhältnisse in die Bewertung eingehen. In Tabelle 6.3 sind die Fehlerwerte dafür abgebildet. Der relative RMSE ist mit 11,39% bzw. 16,04% in beiden Fällen um ca. 2% niedriger als bei der Evaluierung des gesamten Zeitraums (Tabelle 6.2). Der relative MAE ist unter Einbeziehung der Null-Werte um 1,5% niedriger und ohne die Null-Werte identisch. Die mittlere Unterschätzung durch das Modell ist dagegen mit $rBIAS = -4,29\%$ bzw. $-8,50\%$ mehr als doppelt so hoch.

	RMSE	MAE	BIAS	rRMSE (%)	rMAE (%)	rBIAS (%)
$p_{gemessen} \geq 0$	399,81	221,56	-150,49	11,39 %	6,31 %	-4,29 %
$p_{gemessen} > 0$	563,09	439,48	-298,52	16,04 %	12,52 %	-8,50 %

Tabelle 6.3: Fehler des physikalischen Modells für den Zeitraum vom 29.08.2013 bis 13.09.2013 unter Verwendung von Wettervorhersageinformationen.

Zum Vergleich werden für dieselben Zeitpunkte die Fehlerwerte mit den gemessenen Wetterdaten bestimmt (siehe Tabelle 6.4). Wider erwarten sind die Vorhersagefehler in beiden Einteilungen größer als unter Verwendung der Wettervorhersagewerte. Unter Ausschließung der Null-Werte ist der rRMSE mit 17,32% ca. 1%, der rMA mit 12,74% ca. 0,2% und der relative BIAS mit $-10,25\%$ zu $-8,5\%$ größer. Dieses Ergebnis könnte nur durch den zu kleinen Testzeitraum erklärt werden. In zukünftigen

Arbeiten könnte dieser Test mit einem größeren Datenbestand durchgeführt werden.

	RMSE	MAE	BIAS	rRMSE (%)	rMAE (%)	rBIAS (%)
$p_{\text{gemessen}} \geq 0$	431,67	225,42	-181,33	12,30%	6,42%	-5,17%
$p_{\text{gemessen}} > 0$	607,96	447,15	-359,68	17,32%	12,74%	-10,25%

Tabelle 6.4: Fehler des physikalischen Modells für den Zeitraum vom 29.08.2013 bis 13.09.2013 unter Verwendung von gemessenen Wetterdaten.

Für einen Zeitraum von sieben Tagen ist in Abbildung 6.5 die gemessene Leistung der PV-Anlage, die berechnete Leistung basierend auf der Wettervorhersage und die berechnete Leistung auf Basis der gemessenen Wetterdaten dargestellt. Es ist wieder gut zu erkennen, dass in den Morgen- und Abendstunden, wenn die Solarstrahlung klein ist, das PV-Modul keinen Strom erzeugt und deshalb die Leistung zu diesen Zeitpunkten stets unterschätzt wird. Lediglich an Tag eins und sieben kann eine Überschätzung festgestellt werden. Unter Verwendung der Wettervorhersagedaten kann auch am zweiten Tag eine Überschätzung identifiziert werden. Die berechnete Leistung basierend auf der Wettervorhersage und den tatsächlichen Wetterdaten ist an den Tagen fünf und sechs identisch.




Abbildung 6.5: Vergleich der gemessenen PV-Leistung mit der berechneten Leistung auf der Basis von gemessenen und vorhergesagten Wetterdaten.

Es ist zu sehen, dass das physikalische Modell unter der genauen Angabe von Anlagendetails relativ gute Prognosen liefert. Lediglich zu Zeitpunkten, in denen die Solarstrahlung mit weniger als 230 W/m^2 auf das PV-Modul trifft, berechnet das Modell eine Ausgangsleistung von 0 W .

6.3 Künstliches Neuronales Netz

In diesem Unterkapitel werden die im Rahmen dieser Arbeit implementierten und evaluierten KNNs mit verschiedenen Eingabeneuronen und unterschiedlicher Anzahl an verborgenen Neuronen evaluiert. Nachfolgend werden die Null-Werte zur Fehlerberechnung miteinbezogen.

Für das Lernen des KNNs werden 1426 Datensätze vom 01.06.2013 bis 31.07.2013 verwendet, dies entspricht den vom SMA-Wechselrichter gespeicherten Daten von zwei Monaten in stündlicher Auflösung. Die Netze werden zusätzlich mit Daten, die nicht im Trainingssatz enthalten sind, evaluiert. Diese basieren auf den Daten vom 01.08.2013 bis 31.08.2013, was 735 Datensätzen entspricht. Die KNNs werden jeweils mit 1 bis 20 verborgenen Neuronen getestet. Um den Einfluss von zufällig guten oder schlechten initialen Gewichtungen des KNNs zu verringern, wird das Training jeweils 30 Mal durchgeführt.

In Tabelle 6.5 sind basierend auf den 30 Testdurchläufen die kleinsten Fehler für jede Eingabekombination abgebildet. Die hervorgehobenen Zellen entsprechen den Eingabekombinationen mit dem kleinsten Fehler und somit der Empfehlung, welche Eingabeparameter die beste Prognose liefern. Die Bedeutung der Kombinationen stehen in Tabelle 6.6. Sie werden durch Experimente mit nur einem Eingabeparameter bestimmt. Ausführliche Fehlertabellen zu diesen Versuchen sind in Anhang C zu finden. Bei der Verwendung von nur einem Wetterparameter oder der durch den SOLPOS-Algorithmus bestimmten extraterrestrischen Strahlung ist der $rRMSE$ am größten. Der kleinste $rRMSE = 10.23\%$ wird mit Kombination 1 erreicht, der kleinste $rMAE = 6.22\%$ bei Kombination 5 und der kleinste $rBIAS = -0.21\%$ mit Kombination 6. Aufgrund der Tatsache, dass sich die drei verwendeten Fehlermaße für die Kombination 1 bis 8 kaum unterscheiden, Kombination 1 aber den kleinsten $rRMSE$ besitzt, wird die Verwendung von Kombination 1 bei einem RNN mit drei verborgenen Neuronen empfohlen. Vergleicht man diese Erkenntnis mit den Ergebnissen aus der Korrelationsanalyse, dann fällt auf, dass bis auf den Sonnenazimut jeder Parameter einen Korrelationskoeffizienten hat, der entweder negativ oder positiv größer als 0,5 ist. In Abbildung 6.6 ist die berechnete Leistung für die in Tabelle 6.5 markierten Kombinationen dargestellt. Der gewählte Zeitraum ist aus der Mitte des Evaluierungszeitraums zufällig ausgewählt.

Das empfohlene KNN wird als nächstes mit Wettervorhersageinformationen im Zeitraum vom 29.08.2013 bis 13.09.2013 evaluiert. Die Ergebnisse sind in Tabelle 6.7 zu sehen, zudem sind berechnete Vergleichswerte vom physikalischen Modell abgebildet. Es ist zu sehen, dass das KNN mit einem $rRMSE = 10,94\%$ im Gegensatz zum physikalischen Modell $rRMSE = 12,61\%$ die Prognose leicht besser berechnet. Auch der $rMAE$ des KNN ist besser als der des physikalischen Modells. Dies spiegelt sich dann auch im relativen $BIAS$ wieder. Das physikalische Modell unterschätzt die

Eingabeparameter	Verborgene Neuronen	RMSE	rRMSE	Verborgene Neuronen	MAE	rMAE	Verborgene Neuronen	BIAS	rBIAS
Wolkenbedeckung	1	714,00	20,34%	1	602,71	17,17%	1	106,07	3,02%
Extraterr. Solarstrahlung	15	377,30	10,75%	18	220,93	6,29%	19	-34,52	-0,98%
Luftfeuchtigkeit	5	527,79	15,04%	5	383,06	10,91%	5	96,16	2,74%
Niederschlag	10	717,15	20,43%	16	611,26	17,41%	18	115,31	3,29%
Luftdruck	5	704,68	20,08%	5	583,33	16,62%	5	77,68	2,21%
Temperatur	4	470,46	13,40%	11	357,29	10,18%	7	100,33	2,86%
Kombination 1	3	359,02	10,23%	3	218,61	6,23%	19	-22,12	-0,63%
Kombination 2	6	363,46	10,35%	1	228,57	6,51%	18	-17,70	-0,50%
Kombination 3	1	362,24	10,32%	1	221,14	6,30%	17	-28,78	-0,82%
Kombination 4	6	363,69	10,36%	1	227,87	6,49%	20	-17,64	-0,50%
Kombination 5	6	359,61	10,25%	4	218,35	6,22%	20	-21,35	-0,61%
Kombination 6	1	361,11	10,29%	1	220,54	6,28%	19	-7,50	-0,21%
Kombination 7	5	361,99	10,31%	1	219,86	6,26%	20	-35,65	-1,02%
Kombination 8	4	363,08	10,34%	1	223,03	6,35%	17	-12,60	-0,36%

Tabelle 6.5: Prognosefehler der KNNs mit verschiedenen Eingabekombinationen. Die grün markierten Werte stellen jeweils den kleinsten Fehler und somit das optimale KNN dar.

Kombination	Eingabeparameter
1	Sonnenazimut, Sonnenhöhe, Extraterr. Solarstrahlung, Luftfeuchtigkeit, Temperatur
2	Kombination 1 und Wolkenbedeckung
3	Kombination 1 und Luftdruck
4	Kombination 1 und Wolkenbedeckung und Luftdruck
5	Extraterr. Solarstrahlung, Luftfeuchtigkeit, Temperatur
6	Kombination 5 und Wolkenbedeckung
7	Kombination 5 und Luftdruck
8	Kombination 5 und Wolkenbedeckung und Luftdruck

Tabelle 6.6: Beschreibung der Eingabekombinationen.




Abbildung 6.6: Vergleich der Leistungsberechnung von Kombination 1, 5 und 6 mit der tatsächlich gemessenen Leistung. Die x-Achse zeigt den Zeitverlauf in Stunden an. Es handelt sich dabei um vier aufeinanderfolgende Tage ab dem 19.08.2013.

	RMSE	MAE	BIAS	rRMSE	rMAE	rBIAS
Physik. Modell	442,57	235,38	-188,16	12,61%	6,71%	-5,36%
KNN	383,84	192,87	-83,83	10,94%	5,49%	-2,39%

Tabelle 6.7: Vergleich des physikalischen Modells und des KNNs auf Basis von Wettervorhersageinformationen.

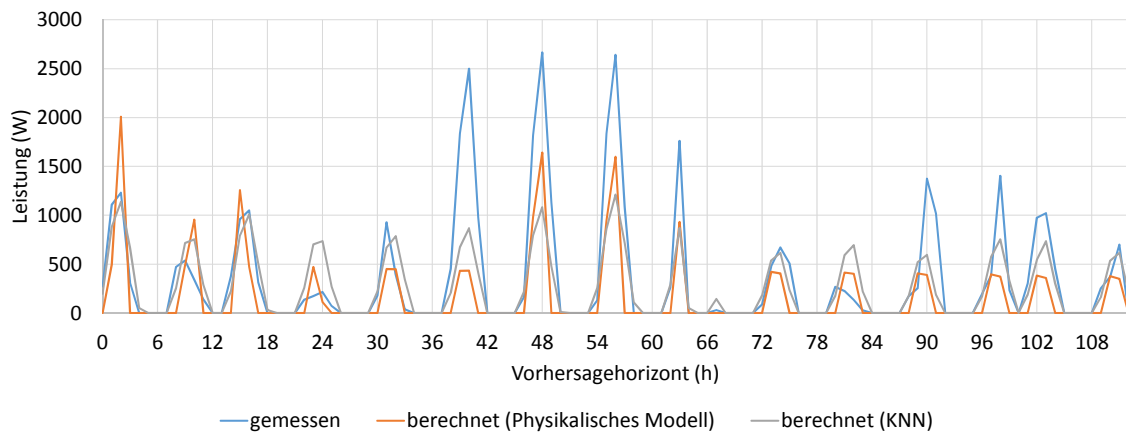


Abbildung 6.7: Vergleich der Prognosekurven beider Modelle basierend auf Wettervorhersageinformationen.

PV-Leistung fast doppelt so stark als das KNN. Die aus dieser Berechnung resultierenden Leistungsprognosen beider Modelle sind mit der tatsächlichen PV-Leistung in Abbildung 6.7 zu sehen.

6.4 Wetterprognose

In diesem Unterkapitel wird die Genauigkeit der verwendeten Wetterprognosen bestimmt. Zur Bestimmung der relativen Fehlermaße werden die absoluten Fehler zum jeweiligen Maximum des Merkmals ins Verhältnis gesetzt. In Tabelle 6.8 sind die Fehler für die Wetterparameter zu finden. Zusätzlich enthält die Tabelle den Mittelwert, die Varianz und die Standardabweichung für die gemessenen Wetterdaten im Zeitraum vom 29.08.2013 zum 13.09.2013, um die Fehlermaße besser interpretieren zu können. Die für das physikalische Modell wichtigsten Parameter sind die Wolkenbedeckung und die Temperatur. Die Wolkenbedeckung wird mit einem rRMSE von 36,61 % vorhergesagt und im Mittel mit einem BIAS von $-11,53\%$ unterschätzt. Die Temperatur wird dagegen mit einem rRMSE von 10,91 % berechnet und bei einem rBIAS von 2,33 % leicht überschätzt. Für das KNN werden die Wetterparameter Temperatur, Luftfeuchtigkeit, Luftdruck und Wolkenbedeckung verwendet. Die Luftfeuchtigkeit wird mit einem rRMSE von 15,05% vorhergesagt und leicht unterschätzt ($rBIAS = -5,03\%$). Es fällt auf, dass der Luftdruck mit einem relativen RMSE von 0,95 % ziemlich genau vorhergesagt, und dieser, bezogen auf seinen

großen Mittelwert von 1015,83, nur sehr leicht bei einer Standardabweichung von 5,46 schwankt.

	Mittelwert	Varianz	Stdabw.	RMSE	MAE	BIAS	rRMSE	rMAE	rBIAS
Temperatur	15,38	17,34	4,16	3,14	2,27	0,67	10,91%	7,89%	2,33%
Rel. Luftfeuchtigkeit	80,81	243,10	15,59	15,05	10,84	-5,03	15,05%	10,84%	-5,03%
Luftdruck	1015,83	29,83	5,46	9,78	9,11	8,92	0,95%	0,89%	0,87%
Windgeschwindigkeit	2,03	5,93	2,44	2,59	1,74	1,18	41,81%	28,04%	19,06%
Wolkenbedeckung	58,58	835,63	28,91	37,83	28,99	-11,30	38,61%	29,58%	-11,53%
Niederschlag	0,04	0,09	0,31	1,24	0,35	0,29	41,35%	11,64%	9,53%

Tabelle 6.8: Mittelwert, Varianz, Standardabweichung und Fehlerwerte der Wetterdaten.

Die Wettervorhersage umfasst einen Prognosehorizont von sieben Tagen. In Abbildung 6.8 sind die relativen RMSE für die verschiedenen Wetterparameter gegen den Vorhersagehorizont aufgetragen. Es ist lediglich beim rRMSE der Wolkenbedeckung und der Temperatur ein größerer Fehler bei größerem Vorhersagehorizont festzustellen. Bei den anderen Wetterparametern bleibt er konstant oder sinkt sogar. Eine Erklärung dafür könnte sein, dass das von Open Weather Map verwendete Prognosemodell keine bessere Wettervorhersage für einen kleineren Vorhersagehorizont liefert. Gleichzeitig muss aber bedacht werden, dass die ausgewerteten Daten lediglich eine Woche des Jahres umfassen und so keine allgemeingültige Aussage getroffen werden kann. In Anhang D.1 sind die Abbildungen zu sehen, die die gemessenen Wetterdaten mit den Wettervorhersagen vergleicht. Detailliertere Abbildungen zur Entwicklung des *rRMSE* bei unterschiedlich langem Vorhersagehorizont sind in Anhang D.2 zu finden.




Abbildung 6.8: Entwicklung des relativen RMSE bezüglich des Vorhersagehorizonts.

6.5 Laufzeit

In diesem Unterkapitel werden die Laufzeiten des KNNs analysiert. Das Training des KNNs benötigt den größten Zeitaufwand. Die Berechnung der Leistungsprognosen mit dem trainierten KNN und dem physikalischen Modell sind dagegen vernachlässigbar klein. Aufgrund der teilweise sehr langen Trainingszeiten der KNNs werden diese auf einem gegenüber dem Raspberry Pi leistungsfähigerem Computer, mit 3 GHz Dual-Core Prozessor und 4 GB Arbeitsspeicher durchgeführt. Die Dauer der Trainings für das KNN mit der Eingabekombination 1 sind in Abbildung 6.9 zu sehen. Auf der x-Achse ist die Anzahl der verborgenen Neuronen in der verborgenen Schicht aufgetragen, auf der y-Achse die Trainingsdauer in Sekunden. Der Versuch wird je Anzahl verborgener Neuronen 30 Mal durchgeführt. Die blaue Linie in der Abbildung entspricht dem Mittelwert aus diesen 30 Versuchen. Als blaue, gepunktete Linie ist die lineare Trendlinie des Mittelwerts eingetragen. Es ist zu sehen, je größer die Anzahl der verborgenen Neuronen ist, desto länger ist die Trainingsdauer. Die orangenen und grauen Balken zeigen die minimale bzw. maximale Dauer für das Training. In Tabelle E.1 sind zusätzlich die Varianz und die Standardabweichung für diesen Versuch zu finden.




Abbildung 6.9: Die Trainingsdauer des KNNs unter Verwendung der Eingabekombination 1.

In Kapitel 6.3 wird das KNN mit den Eingabeparametern Sonnenazimut, Sonnenhöhe, extraterrestrischer Solarstrahlung, Luftfeuchtigkeit und Temperatur bei drei verborgenen Neuronen in der verborgenen Schicht empfohlen. Die Laufzeiten des Trainings bei 1426 Datensätzen sind in Tabelle 6.9 zu sehen. Dabei fällt auf, dass die Spannweite der Trainingsdauer auf dem PC bei 49s liegt, auf dem Raspberry Pi bei 326s. Im Durchschnitt benötigt das Training 321s, auf dem PC nur 29s. Trotz der großen Unterschiede von PC und Raspberry Pi, ist die Trainingsdauer auf dem Raspberry Pi noch vertretbar und somit auch praxistauglich.

Verborgene Neuronen	Minimum (s)	Maximum (s)	Mittelwert (s)	Stdabw. (s)	Varianz (s)
3	180	506	321,2	83,2	7165,6

Tabelle 6.9: Trainingsdauer des KNNs mit den empfohlenen Eingabeparametern, drei verborgenen Neuronen und 1426 Datensätzen auf dem Raspberry Pi.

6.6 Zusammenfassung

In diesem Kapitel wurden die im Rahmen der Arbeit entwickelten Modelle bezüglich ihrer Eignung für die Prognose der PV-Leistung bewertet. Als Evaluationskriterien wurden der $RMSE$, MAE und $BIAS$ als absolutes Fehlermaß verwendet. Um einen relativen Fehler angeben zu können, wurden diese mit der Peak-Leistung der PV-Anlage normalisiert. Es wurde eine **Korrelationsanalyse durchgeführt, bei der sich herausstellte, dass die Temperatur, die Sonnenhöhe und die extraterrestrische Globalstrahlung den stärksten positiven Einfluss auf die PV-Leistung haben und die relative Luftfeuchtigkeit den stärksten negativen Einfluss.**

Zur Evaluierung des physikalischen Modells standen 2494 Datensätze zwischen dem 30.05.2013 und dem 14.09.2013 zur Verfügung. Das Modell berechnet die PV-Leistung mit einem $rRMSE$ von 14,5 % unter Miteinbeziehung der nächtlichen Leistungswerte von Null. Bei Ausschluss der nächtlichen Leistungswerte von Null vergrößert sich der $rRMSE$ auf 18,16 %, was aber trotzdem einer guten Prognose entspricht.

Die untersuchten KNNs wurden mit 1426 Datensätzen vom 01.06.2013 bis 31.08.2013 trainiert und mit 735 Datensätzen vom 01.08.2013 bis 31.08.2013 evaluiert. Es zeigte sich, dass das KNN mit fünf Eingabeneuronen und den Parametern Sonnenazimut, Sonnenhöhe, extraterrestrische Solarstrahlung, Luftfeuchtigkeit und Temperatur mit Hilfe drei verborgener Neuronen die beste Prognose mit einem $rRMSE = 10,23\%$ liefert.

Die Berechnungsdauer der Leistungsprognose ist, sowohl für das physikalische Modell, als auch für das KNN vernachlässigbar klein. Das Training des empfohlenen KNNs benötigt auf einem Raspberry Pi im Durchschnitt ca. 321 s, was für einen Praxiseinsatz ausreichend ist.

Zusätzlich wurden die vom Wetterdienst bezogenen Wetterprognosen evaluiert. Dabei stellt sich heraus, dass sich der $rRMSE$ bei wachsendem Vorhersagehorizont nur unwesentlich vergrößert. Zukünftige Arbeiten könnten weiterhin die Gültigkeit der Prognosen mit umfangreicheren Daten, z. B. für ein ganzes Jahr, prüfen.

7. Zusammenfassung und Ausblick

Das Ziel dieser Arbeit ist historische Leistungsdaten eines SMA-Solar-Wechselrichters via Bluetooth auszulesen, diese mit aktuellen Wetterdaten zu fusionieren und mittels Wetterprognosen eine Leistungsvorhersage der PV-Anlage zu erstellen. Dies soll unter der Bedingung geschehen, dass die Implementierungen der Modelle auf einem Raspberry Pi lauffähig sind und die Wetterinformationen von einem Wetterdienst kostenfrei zur Verfügung gestellt werden. Zudem soll das gewählte Verfahren nur wenige Angaben zur PV-Anlage und deren Umgebung benötigen.

Die Kommunikation über Bluetooth mit dem Wechselrichter wird durch das Tool SMAspot realisiert. Damit können historische und aktuelle Leistungsdaten als CSV-Dateien abgerufen werden. Es werden zwei Vorhersagemodelle betrachtet, evaluiert und implementiert. Um der Anforderung, keine detaillierten Kenntnisse über die PV-Anlage und deren Umgebung zu benötigen, gerecht zu werden, ist ein Prognosemodell auf Basis eines rekursiven neuronalen Netzes gewählt worden. Der Vorteil eines KNNs liegt darin, dass es lediglich mit historischen Leistungs- und Wetterdaten trainiert werden muss, um Prognosen erstellen zu können. Da dieses Training vor jeder Leistungsvorhersage mit den letzten aufgezeichneten Leistungsdaten durchgeführt wird, kann es sich an neue Bedingungen wie z. B. Jahreszeiten, Beschattung oder eine zunehmende Verschmutzung des Solarmoduls anpassen.

Zusätzlich wird ein physikalisches Modell implementiert, das versucht die physikalischen Prozesse der Komponenten einer PV-Anlage zu simulieren. Dieses benötigt allerdings detaillierte Informationen über die PV-Anlage. Obwohl selbst für die betrachtete Anlage nicht alle Informationen vorhanden waren, überzeugt das Modell mit guten Prognosen. Das KNN prognostizierte die Leistung mit einem $rRMSE$ von 10,23 %, das physikalische Modell mit 18,16 %, was jeweils einem sehr guten Wert entspricht. Zudem ist das initiale Training des KNNs auf dem Raspberry Pi im Durchschnitt nach akzeptablen 321 s abgeschlossen.

Die Modelle wurden aufgrund des vorhandenen Datenbestands nur für die Monate Juni bis September evaluiert, unter Verwendung von Wettervorhersagedaten nur für eine Woche im September. Zukünftige Arbeiten könnten deshalb eine Analyse der Modelle für die restlichen Monate durchführen, um eine allgemeingültige Aussage über die Güte der Modelle treffen zu können. Zudem könnte geprüft werden, inwiefern sich die Leistung des KNNs verändert, wenn die berechnete Leistung des physikalischen Modells als Eingabeparameter für das KNN verwendet wird.

A. Properties-Datei

```
plz=30880
countryCode=DE
dbPath=../pv.sqlite3.db
importerLogPath=pv_rpi_csv2sqlite.log
weatherLogPath=pv_rpi_lookupWeather.log
fusionerLogPath=pv_rpi_fusioner.log
trainerLogPath=pv_rpi_trainer.log
#       The location of PV data files (CSV-Files).
#       (e.g. /home/pi/smaspot/smaspot-data)
dataPath=/home/pi/smaspot/smaspot-data
# OWM APP ID
appId:b16b71ae986a87aef1cdc92db191194b
# Path for forecast results.
exportPath=./
# Path to NN file.
nnFileName=./nn_k8_6_27.eg
#####
# Inverter properties
#####
# AC Nominal Power in Watt (Output)
nominalPowerAC=3000
# DC Max Power in Watt (Input)
maxPowerDC=3200
# Efficiency at 10% of nominal power
eta10=0.933
# Efficiency at 50% of nominal power
```

```
eta50 = 0.969
# Efficiency at 100% of nominal power
eta100 = 0.97
# Nominal Efficiency
etaNominal = 0.97
# [input|output] efficiency
efficiencyType = output
#####
# PV Module properties
#####
# azimuth angle in degrees (0 = south, 180 = north)
azimuth = 0
# inclination angle in degrees
inclination = 45
# area in m^2
area = 23
# max power in Watt
power = 3510
# if module is installed on
# rooftop (0.0568), detached (0.02)
installationLocationCoefficient = 0.0568
# temperature coefficient
temperatureCoefficient = -0.0047
# model specific parameters
a1 = 0.2004
a2 = -0.0001398
a3 = 0.1351
```

Listing A.1: Properties-Date zur Konfiguration der implementierten Applikationen.

B. Datenbankschemata

Im Folgenden werden die Tabellen der Datenbank schematisch dargestellt.

Spaltenname	Datentyp	Besonderheit
timestamp	Integer	Primary Key
plz	Integer	
kwh	Real	
kw	Real	

Abbildung B.1: Schema der Tabelle pv_data.

Spaltenname	Datentyp	Besonderheit
timestamp	Integer	Primary Key
plz	Integer	
kwh	Real	

Abbildung B.2: Schema der Tabelle pv_energy.

Spaltenname	Datentyp	Besonderheit
timestamp	Integer	Primary Key
azimuth_angle	Real	
elevation_angle	Real	
global_etr	Real	

Abbildung B.3: Schema der Tabelle solpos.

Spaltenname	Datentyp	Besonderheit
timestamp	Integer	Primary Key
city_id	Integer	
city_name	Integer	
plz	Integer	
country_code	Text	
lon	Real	
lat	Real	
sunrise	Integer	
sunset	Integer	
temp	Real	
temp_max	Real	
temp_min	Real	
temp_unit	Text	
humidity	Real	
humidity_unit	Text	
pressure	Real	
pressure_unit	Text	
wind_speed	Real	
wind_direction	Integer	
wind_direction_name	Text	
cloud_cover	Integer	
precipitation	Real	
precipitation_mode	Text	
precipitation_unit	Text	

Abbildung B.4: Schema der Tabelle current_weather.

Spaltenname	Datentyp	Besonderheit
timestamp	Integer	Primary Key
city_id	Integer	
city_name	Text	
plz	Integer	
country_code	Text	
lon	Real	
lat	Real	
sunrise	Integer	
sunset	Integer	
temp	Real	
temp_max	Real	
temp_min	Real	
temp_unit	Text	
humidity	Real	
humidity_unit	Text	
pressure	Real	
pressure_unit	Text	
wind_speed	Real	
wind_direction	Integer	
wind_direction_name	Text	
cloud_cover	Integer	
precipitation	Real	
precipitation_mode	Text	
precipitation_unit	Text	
request_timestamp	Integer	Primary Key

Abbildung B.5: Schema der Tabelle weather_forecast.

Spaltenname	Datentyp	Besonderheit
timestamp	Integer	Primary Key
physical_model_energy	Real	
nn_model_energy	Real	

Abbildung B.6: Schema der Tabelle power_forecast.

C. Fehlertabellen der KNNs bei einem Eingabeneuron

In den nachfolgenden Tabellen ist die Auswertung der KNNs mit jeweils einem Eingabeneuron zu sehen. Diese Tabellen dienen als Grundlage zur Bildung der Eingabekombinationen.

Anzahl verborgener Neuronen	RMSE	MAE	BIAS	rRMSE	rMAE	rBIAS
1	662,69	535,58	140,11	24,69%	19,95%	5,22%
2	558,79	457,28	318,26	20,82%	17,04%	11,86%
3	540,62	432,70	303,06	20,14%	16,12%	11,29%
4	546,58	439,76	310,35	20,36%	16,38%	11,56%
5	498,12	391,94	254,42	18,56%	14,60%	9,48%
6	496,25	392,46	251,74	18,49%	14,62%	9,38%
7	483,93	375,50	237,89	18,03%	13,99%	8,86%
8	477,62	366,68	230,16	17,79%	13,66%	8,57%
9	473,85	362,18	226,88	17,65%	13,49%	8,45%
10	470,29	355,15	222,03	17,52%	13,23%	8,27%
11	469,71	356,84	221,49	17,50%	13,29%	8,25%
12	463,52	347,52	210,42	17,27%	12,95%	7,84%
13	467,25	348,37	215,87	17,41%	12,98%	8,04%
14	465,52	346,96	213,57	17,34%	12,93%	7,96%
15	458,33	333,52	204,59	17,08%	12,43%	7,62%
16	460,53	338,85	208,40	17,16%	12,62%	7,76%
17	458,97	333,48	206,15	17,10%	12,42%	7,68%
18	461,59	340,61	209,60	17,20%	12,69%	7,81%
19	461,27	337,41	210,71	17,19%	12,57%	7,85%
20	459,41	331,28	205,10	17,12%	12,34%	7,64%

Tabelle C.1: Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Sonnenazimut.

Anzahl verborgener Neuronen	RMSE	MAE	BIAS	rRMSE	rMAE	rBIAS
1	714,00	602,71	106,07	20,34%	17,17%	3,02%
2	727,07	620,92	165,31	20,71%	17,69%	4,71%
3	729,02	623,59	171,62	20,77%	17,77%	4,89%
4	731,64	625,65	177,88	20,84%	17,82%	5,07%
5	730,09	623,16	169,54	20,80%	17,75%	4,83%
6	729,14	620,52	164,11	20,77%	17,68%	4,68%
7	724,83	618,04	156,89	20,65%	17,61%	4,47%
8	721,78	614,91	149,95	20,56%	17,52%	4,27%
9	723,78	615,28	149,27	20,62%	17,53%	4,25%
10	716,62	609,23	137,98	20,42%	17,36%	3,93%
11	717,09	609,17	136,08	20,43%	17,36%	3,88%
12	717,30	609,89	139,47	20,44%	17,38%	3,97%
13	716,35	608,53	136,93	20,41%	17,34%	3,90%
14	717,19	609,01	136,99	20,43%	17,35%	3,90%
15	715,78	608,08	135,20	20,39%	17,32%	3,85%
16	716,45	608,55	135,18	20,41%	17,34%	3,85%
17	716,42	608,42	135,12	20,41%	17,33%	3,85%
18	716,16	608,69	136,59	20,40%	17,34%	3,89%
19	717,26	610,16	137,91	20,43%	17,38%	3,93%
20	715,82	607,55	133,30	20,39%	17,31%	3,80%

Tabelle C.2: Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Wolkenbedeckung.

Anzahl verborgener Neuronen	RMSE	MAE	BIAS	rRMSE	rMAE	rBIAS
1	396,33	250,88	-80,99	14,77%	9,35%	-3,02%
2	396,18	247,53	-86,77	14,76%	9,22%	-3,23%
3	396,22	249,82	-81,33	14,76%	9,31%	-3,03%
4	395,79	250,27	-83,80	14,75%	9,32%	-3,12%
5	394,87	243,73	-82,98	14,71%	9,08%	-3,09%
6	394,76	247,73	-80,45	14,71%	9,23%	-3,00%
7	392,90	240,16	-82,03	14,64%	8,95%	-3,06%
8	391,41	236,76	-75,16	14,58%	8,82%	-2,80%
9	389,72	233,66	-73,83	14,52%	8,71%	-2,75%
10	388,39	232,41	-71,02	14,47%	8,66%	-2,65%
11	386,18	230,43	-65,63	14,39%	8,59%	-2,45%
12	386,28	230,65	-65,33	14,39%	8,59%	-2,43%
13	383,05	227,15	-59,86	14,27%	8,46%	-2,23%
14	383,59	227,73	-60,69	14,29%	8,48%	-2,26%
15	382,68	227,95	-59,25	14,26%	8,49%	-2,21%
16	381,91	224,77	-52,33	14,23%	8,37%	-1,95%
17	383,21	226,70	-54,38	14,28%	8,45%	-2,03%
18	382,28	226,17	-47,40	14,24%	8,43%	-1,77%
19	380,98	225,92	-48,09	14,19%	8,42%	-1,79%
20	383,49	226,62	-46,77	14,29%	8,44%	-1,74%

Tabelle C.3: Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Sonnenhöhe.

Anzahl verborgener Neuronen	RMSE	MAE	BIAS	rRMSE	rMAE	rBIAS
1	383,91	229,38	-66,89	10,94%	6,53%	-1,91%
2	383,73	226,90	-64,59	10,93%	6,46%	-1,84%
3	384,14	227,40	-62,28	10,94%	6,48%	-1,77%
4	382,86	224,47	-61,31	10,91%	6,40%	-1,75%
5	381,89	225,23	-56,58	10,88%	6,42%	-1,61%
6	380,53	224,04	-52,46	10,84%	6,38%	-1,49%
7	380,14	223,71	-50,33	10,83%	6,37%	-1,43%
8	380,31	222,49	-50,96	10,83%	6,34%	-1,45%
9	379,55	223,62	-45,47	10,81%	6,37%	-1,30%
10	377,64	222,57	-41,99	10,76%	6,34%	-1,20%
11	378,74	221,45	-41,67	10,79%	6,31%	-1,19%
12	378,41	221,95	-43,98	10,78%	6,32%	-1,25%
13	377,62	221,84	-40,53	10,76%	6,32%	-1,15%
14	379,45	221,16	-40,01	10,81%	6,30%	-1,14%
15	377,30	221,81	-39,88	10,75%	6,32%	-1,14%
16	379,02	223,23	-37,28	10,80%	6,36%	-1,06%
17	383,06	221,23	-37,81	10,91%	6,30%	-1,08%
18	379,54	220,93	-38,59	10,81%	6,29%	-1,10%
19	381,45	221,43	-34,52	10,87%	6,31%	-0,98%
20	386,22	225,27	-34,72	11,00%	6,42%	-0,99%

Tabelle C.4: Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter extraterrestrische Globalstrahlung.

Anzahl verborgener Neuronen	RMSE	MAE	BIAS	rRMSE	rMAE	rBIAS
1	625,99	467,39	91,89	23,32%	17,41%	3,42%
2	469,67	360,99	98,48	17,50%	13,45%	3,67%
3	462,12	350,12	96,24	17,22%	13,04%	3,59%
4	456,99	344,93	90,79	17,03%	12,85%	3,38%
5	458,38	345,54	93,40	17,08%	12,87%	3,48%
6	447,18	329,19	95,88	16,66%	12,26%	3,57%
7	442,60	320,48	97,02	16,49%	11,94%	3,61%
8	441,30	321,12	98,94	16,44%	11,96%	3,69%
9	433,72	306,56	97,90	16,16%	11,42%	3,65%
10	435,56	311,77	95,38	16,23%	11,62%	3,55%
11	432,38	307,01	94,80	16,11%	11,44%	3,53%
12	430,93	302,05	95,50	16,05%	11,25%	3,56%
13	428,69	298,92	95,89	15,97%	11,14%	3,57%
14	425,02	291,71	95,76	15,83%	10,87%	3,57%
15	424,70	291,69	97,66	15,82%	10,87%	3,64%
16	423,17	285,17	96,85	15,77%	10,62%	3,61%
17	424,64	287,51	96,58	15,82%	10,71%	3,60%
18	419,69	278,54	97,15	15,64%	10,38%	3,62%
19	421,06	279,13	96,49	15,69%	10,40%	3,59%
20	421,00	279,92	97,73	15,68%	10,43%	3,64%

Tabelle C.5: Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Tagesstunde.

Anzahl verborgener Neuronen	RMSE	MAE	BIAS	rRMSE	rMAE	rBIAS
1	639,28	495,67	149,58	18,21%	14,12%	4,26%
2	580,15	436,59	122,80	16,53%	12,44%	3,50%
3	552,66	408,72	112,25	15,75%	11,64%	3,20%
4	542,19	400,01	112,16	15,45%	11,40%	3,20%
5	527,79	383,06	96,16	15,04%	10,91%	2,74%
6	553,21	410,37	112,05	15,76%	11,69%	3,19%
7	555,86	410,25	108,09	15,84%	11,69%	3,08%
8	574,41	427,91	123,50	16,37%	12,19%	3,52%
9	569,77	422,73	121,76	16,23%	12,04%	3,47%
10	573,32	428,29	130,39	16,33%	12,20%	3,71%
11	595,05	445,20	129,96	16,95%	12,68%	3,70%
12	606,35	458,69	141,39	17,27%	13,07%	4,03%
13	616,55	469,81	144,81	17,57%	13,38%	4,13%
14	617,69	471,24	148,08	17,60%	13,43%	4,22%
15	631,08	484,95	154,49	17,98%	13,82%	4,40%
16	638,21	491,39	154,50	18,18%	14,00%	4,40%
17	626,28	479,37	150,44	17,84%	13,66%	4,29%
18	645,30	497,48	158,63	18,38%	14,17%	4,52%
19	644,79	496,89	157,68	18,37%	14,16%	4,49%
20	641,65	494,50	156,55	18,28%	14,09%	4,46%

Tabelle C.6: Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter relative Luftfeuchtigkeit.

Anzahl verborgener Neuronen	RMSE	MAE	BIAS	rRMSE	rMAE	rBIAS
1	717,97	614,20	121,65	20,46%	17,50%	3,47%
2	718,28	614,73	122,45	20,46%	17,51%	3,49%
3	718,38	615,25	124,14	20,47%	17,53%	3,54%
4	717,61	613,96	121,47	20,44%	17,49%	3,46%
5	718,64	615,42	123,65	20,47%	17,53%	3,52%
6	717,49	613,57	120,19	20,44%	17,48%	3,42%
7	717,89	614,38	122,54	20,45%	17,50%	3,49%
8	718,22	614,34	122,31	20,46%	17,50%	3,48%
9	717,99	613,44	119,84	20,46%	17,48%	3,41%
10	717,15	612,63	118,71	20,43%	17,45%	3,38%
11	718,28	614,49	121,76	20,46%	17,51%	3,47%
12	717,26	612,58	118,62	20,43%	17,45%	3,38%
13	717,56	612,56	118,20	20,44%	17,45%	3,37%
14	717,69	613,02	118,83	20,45%	17,46%	3,39%
15	717,79	613,19	119,61	20,45%	17,47%	3,41%
16	717,25	611,26	115,67	20,43%	17,41%	3,30%
17	717,56	612,24	116,43	20,44%	17,44%	3,32%
18	717,45	611,49	115,31	20,44%	17,42%	3,29%
19	717,73	612,37	117,84	20,45%	17,45%	3,36%
20	718,23	613,19	118,93	20,46%	17,47%	3,39%

Tabelle C.7: Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Niederschlag.

Anzahl verborgener Neuronen	RMSE	MAE	BIAS	rRMSE	rMAE	rBIAS
1	707,43	588,54	81,49	20,15%	16,77%	2,32%
2	707,70	589,25	83,43	20,16%	16,79%	2,38%
3	707,43	588,40	81,58	20,15%	16,76%	2,32%
4	706,85	587,78	83,16	20,14%	16,75%	2,37%
5	704,68	583,33	77,68	20,08%	16,62%	2,21%
6	706,65	587,85	82,06	20,13%	16,75%	2,34%
7	706,31	586,75	80,94	20,12%	16,72%	2,31%
8	706,27	586,74	81,73	20,12%	16,72%	2,33%
9	705,00	584,16	79,26	20,09%	16,64%	2,26%
10	707,85	588,50	84,47	20,17%	16,77%	2,41%
11	706,43	586,78	83,12	20,13%	16,72%	2,37%
12	706,03	586,24	82,32	20,11%	16,70%	2,35%
13	707,13	588,68	85,49	20,15%	16,77%	2,44%
14	705,85	585,13	80,00	20,11%	16,67%	2,28%
15	707,51	587,94	81,47	20,16%	16,75%	2,32%
16	706,68	585,80	80,31	20,13%	16,69%	2,29%
17	707,39	589,20	86,43	20,15%	16,79%	2,46%
18	707,90	590,29	87,54	20,17%	16,82%	2,49%
19	707,90	588,95	84,90	20,17%	16,78%	2,42%
20	708,36	589,36	84,47	20,18%	16,79%	2,41%

Tabelle C.8: Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Luftdruck.

Anzahl verborgener Neuronen	RMSE	MAE	BIAS	rRMSE	rMAE	rBIAS
1	592,18	485,89	155,58	16,87%	13,84%	4,43%
2	502,54	391,80	122,63	14,32%	11,16%	3,49%
3	477,74	364,67	107,01	13,61%	10,39%	3,05%
4	470,46	359,43	106,58	13,40%	10,24%	3,04%
5	470,57	358,38	105,84	13,41%	10,21%	3,02%
6	471,29	358,38	106,91	13,43%	10,21%	3,05%
7	472,90	358,74	100,33	13,47%	10,22%	2,86%
8	473,53	359,91	109,85	13,49%	10,25%	3,13%
9	476,25	363,40	111,83	13,57%	10,35%	3,19%
10	475,30	361,14	109,07	13,54%	10,29%	3,11%
11	471,88	357,29	108,98	13,44%	10,18%	3,10%
12	482,47	366,98	114,51	13,75%	10,46%	3,26%
13	473,96	358,24	109,87	13,50%	10,21%	3,13%
14	484,58	369,10	115,33	13,81%	10,52%	3,29%
15	486,16	370,24	117,86	13,85%	10,55%	3,36%
16	492,56	375,07	120,17	14,03%	10,69%	3,42%
17	484,86	364,88	118,93	13,81%	10,40%	3,39%
18	484,11	369,90	125,97	13,79%	10,54%	3,59%
19	487,40	370,33	122,43	13,89%	10,55%	3,49%
20	490,88	374,40	123,00	13,99%	10,67%	3,50%

Tabelle C.9: Ausführliche Fehlertabelle des KNNs mit dem Eingabeparameter Temperatur.

D. Wetterprognose

Im Folgenden werden die verschiedenen Wetterparameter in Abhängigkeit des Vorhersagehorizonts dargestellt.

D.1 Vorhersage der Wetterparameter für den gesamten Vorhersagehorizont

In diesem Unterkapitel wird das vorhergesagte Wetter mit dem tatsächlich aufgetretenen Wetter verglichen. Dazu werden für jeden Wetterparameter, der vorhergesagte und der gemessene Wert, als Liniendiagramm angezeigt.




Abbildung D.1: Verlauf der vorhergesagten und gemessenen Wolkenbedeckung.




Abbildung D.2: Verlauf der vorhergesagten und gemessenen Luftfeuchtigkeit.




Abbildung D.3: Verlauf des vorhergesagten und gemessenen Niederschlags.




Abbildung D.4: Verlauf des vorhergesagten und gemessenen Luftdrucks.




Abbildung D.5: Verlauf der vorhergesagten und gemessenen Temperatur.




Abbildung D.6: Verlauf der vorhergesagten und gemessenen Windgeschwindigkeit.

D.2 Prognosefehler in Abhängigkeit des Vorhersagehorizontes

In diesem Kapitel werden die Fehler der einzelnen Wetterparameter in Abhängigkeit des Vorhersagehorizonts in den Abbildungen grafisch dargestellt.




Abbildung D.7: Fehleranalyse der Wolkenbedeckung bezüglich des Vorhersagehorizonts.




Abbildung D.8: Fehleranalyse des Luftdrucks bezüglich des Vorhersagehorizonts.

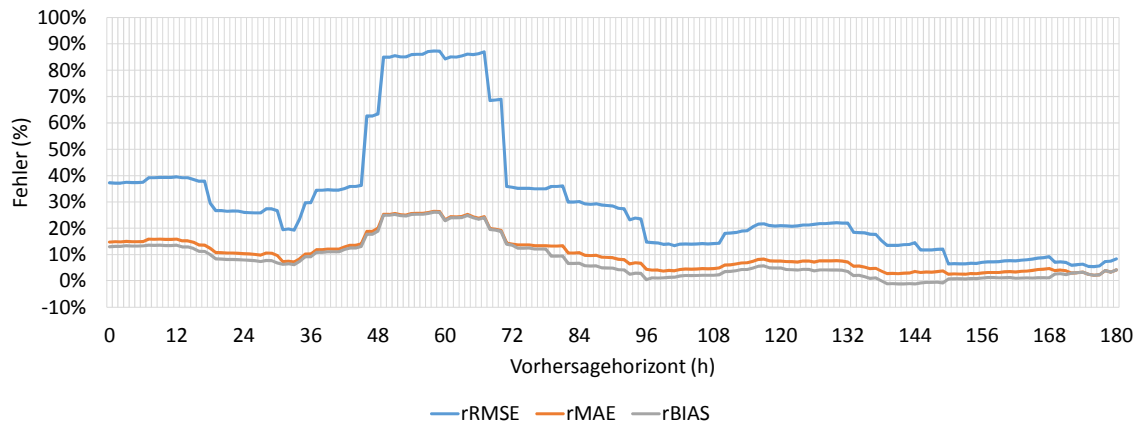


Abbildung D.9: Fehleranalyse des Niederschlags bezüglich des Vorhersagehorizonts.




Abbildung D.10: Fehleranalyse der Temperatur bezüglich des Vorhersagehorizonts.

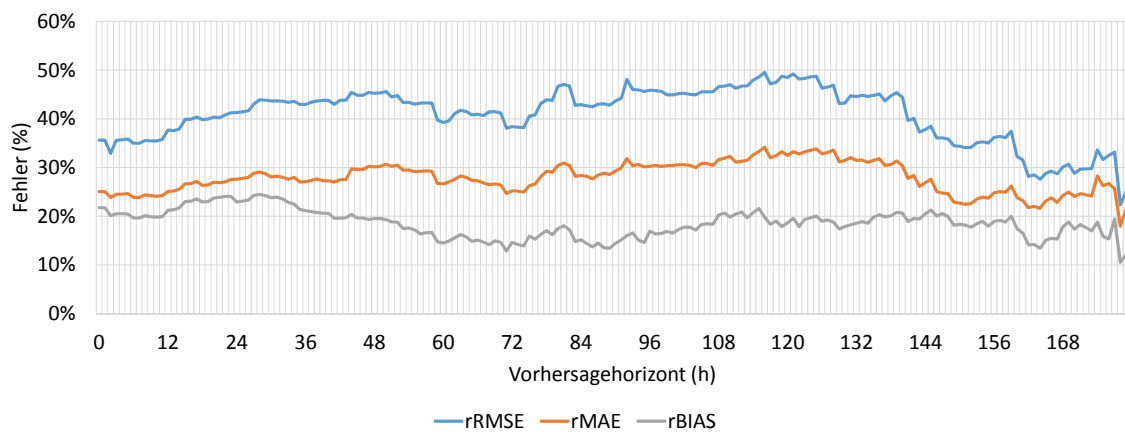


Abbildung D.11: Fehleranalyse der Windgeschwindigkeit bezüglich des Vorhersagehorizonts.

E. Laufzeitanalyse

Tabelle E.1 zeigt die Analyse der Trainingsdauern auf dem Raspberry Pi. Es wird das KNN mit der Eingabe Sonnenazimut, Sonnenhöhe, extraterrestrische Solarstrahlung, Luftfeuchtigkeit und Temperatur bei drei verborgenen Neuronen verwendet.

Verborgene Neuronen	Minimum (s)	Maximum (s)	Mittelwert (s)	Stdabw. (s)	Varianz (s)
1	6	28	16,6	5,1	26,4
2	11	39	21,2	6,7	44,8
3	15	64	29,0	11,5	133,0
4	14	77	34,6	13,2	175,4
5	15	68	41,8	15,1	229,4
6	11	94	43,2	17,5	305,9
7	15	74	39,6	15,1	229,1
8	24	340	67,4	54,2	2938,9
9	24	136	61,7	25,4	644,5
10	31	547	126,0	141,4	19994,6
11	37	560	155,1	159,1	25297,4
12	38	752	193,5	182,6	33351,0
13	45	582	219,2	186,5	34770,3
14	50	926	344,8	274,8	75515,6
15	66	806	278,5	242,6	58861,7
16	40	1100	552,2	309,9	96046,8
17	47	830	502,0	286,2	81926,4
18	33	747	380,1	227,4	51733,2
19	25	505	320,6	146,7	21521,6
20	55	556	400,1	112,5	12657,8

Tabelle E.1: Analyse der Trainingsdauer des empfohlenen KNNs unter Verwendung der Eingabekombination 1.

F. Datenträgerinhalt

Auf der beigelegten DVD befinden sich neben der finalen Ausarbeitung als PDF-Datei, folgende Inhalte:

- **Daten zur Bestimmung des besten KNNs:** Es befinden sich alle erstellten und bewerteten KNNs in diesem Verzeichnis. Die Unterordner „#1“ bis „#4“ entsprechen dabei der zeitlichen Vorgehensweise. Es wurden zuerst nicht normalisiert Eingabeparameter verwendet und nur das Netz mit dem niedrigsten Fehler nach dem Training zur Evaluierung verwendet („#1“). Da dies keine zufriedenstellenden Ergebnisse bracht wurde in „#2“ jedes Netz zur Evaluierung verwendet. Aber auch das brachte keine Besserung. In „#3“ wurden alle Eingabeparameter normalisiert und zusätzlich die Uhrzeit des Tages als Parameter hinzugefügt. Die Auswertungen in „#4“ wurden dazu verwendet, um die einzelnen Eingabeparameter auf deren Einfluss gegenüber der Leistungsprognose zu bestimmen.
- **Encog:** Enthält das komplette Encog-Framework, bestehend aus der Java-Bibliothek, einigen Beispielen und der Encog-Workbench, mit der die erstellten KNNs visuell dargestellt werden können.
- **Evaluierung:** Enthält die SQLite-Datenbank, CSV- und Excel-Dateien, die zur Evaluierung eingesetzt wurden.
- **Implementierung:** Die Implementierung enthält die finalen Programme die im Rahmen dieser Arbeit entwickelt wurden. Zudem sind der angepasste Client zur Kommunikation mit Open Weather Map (owmClient) und der in Java implementierte SOLPOS-Algorithmus (SolposJava) vorhanden. In „PhysicalPv-PowerForecastModel“ befindet sich das Auswertungsprogramm zur Leistungsprognose für das physikalische Modell. „WeatherForecastAccuracy“ dient zur

Auswertung der von Open Weather Map zur Verfügung gestellten Wetterprognosen. Die „Tools zum Festellen des besten KNNs“ enthalten den Java-Code, mit dem die verschiedenen KNNs implementiert wurden.

- **LaTeX:** Enthält den kompletten TeX-Code der Ausarbeitung inkl. Abbildungen, Anhängen, Bibtex-Datei und Tabellen.
- **Libraries:** Enthalten die zur Ausführung der implementierten Programmen notwendigen Java-Bibliotheken.
- **Online-Literatur:** Die verwendete Online-Literatur ist in diesem Verzeichnis als PDF-Dateien verfügbar.
- **SOLPOS C Code:** Der C-Code des *SOLPOS*-Algorithmus.
- **Wechselrichterkommunikation:** Das verwendete Programm *SMAspot* und eine Installationsanleitung sind dort zu finden.
- **Zwischenpräsentation:** Die Zwischenpräsentation der Arbeit.

Literaturverzeichnis

- [Alle97] R. Allen. Self-Calibrating Method for Estimating Solar Radiation from Air Temperature. *Journal of Hydrologic Engineering* 2(2), 1997, S. 56–67.
- [Almo11] J. Almorox. Estimating global solar radiation from common meteorological data in Aranjuez, Spain. *Turk. J. Phys* Band 35, 2011, S. 53–64.
- [BBDH⁺04] H. G. Beyer, J. Betcke, A. Drews, D. Heinemann, E. Lorenz, G. Heilscher und S. Bofinger. Identification of a General Model for the MPP Performance of PV-Modules for the Application in a Procedure for the Performance Check of Grid Connected Systems. In *19th European Photovoltaic Solar Energy Conference and Exhibition, Paris, France*, Band 7, 2004, S. 2004.
- [BMWi10] BMWi, BMU. Energiekonzept für eine umweltschonende, zuverlässige und bezahlbare Energieversorgung. *Bundesministerium für Wirtschaft und Technologie (BMWi), Bundesministerium für Umwelt, Naturschutz und Reaktorsicherheit (BMU), Berlin*, 2010.
- [BMWi12] BMWi, BMU. Stromversorgung, 2012. <http://www.bmwi.de/DE/Themen/Energie/stromversorgung.html>, Zugriff am 27. September 2013.
- [BoHe06] S. Bofinger und G. Heilscher. Solar electricity forecast-approaches and first results. In *Proc. of the 21st European Photovoltaic Solar Energy Conference*, 2006.
- [BrCa84] K. L. Bristow und G. S. Campbell. On the relationship between incoming solar radiation and daily maximum and minimum temperature. *Agricultural and Forest Meteorology* 31(2), Mai 1984, S. 159–166.
- [Coll12] S. Collier. sma-bluetooth, Juni 2012. <https://code.google.com/p/sma-bluetooth/>, Zugriff am 1. Juli 2013.

- [DDL12] H. M. Diagne, M. David, P. Lauret und J. Boland. Solar Irradiation Forecasting: State-of-the-art and Proposition for Future Developments for Small-scale Insular Grids. In *Proceedings of the World Renewable Energy Forum 2012 (WREF 2012)*, Denver, USA, Mai 2012. American Solar Energy Society.
- [Deut85] Deutsches Institut für Normung e. V. Tageslicht in Innenräumen; Grundlagen, 1985.
- [DPAA08] M. Drif, P. Pérez, J. Aguilera und J. Aguilar. A new estimation method of irradiance on a partially shaded PV generator in grid-connected photovoltaic systems. *Renewable Energy* 33(9), September 2008, S. 2048–2056.
- [ECMW13] ECMWF. European Centre for Medium-Range Weather Forecasts, 2013. <http://www.ecmwf.int/>, Zugriff am 18. September 2013.
- [Elma91] J. L. Elman. Distributed representations, simple recurrent networks, and grammatical structure. *Machine Learning* 7(2-3), September 1991, S. 195–225.
- [GILo72] H. R. Glahn und D. A. Lowry. The Use of Model Output Statistics (MOS) in Objective Weather Forecasting. *Journal of Applied Meteorology* 11(8), Dezember 1972, S. 1203–1211.
- [GuMK98] M. S. Gul, T. Muneer und H. D. Kambezidis. Models for obtaining solar radiation from other meteorological data. *Solar Energy* 64(1–3), September 1998, S. 99–108.
- [GwCr95] B. Gwandu und D. Creasey. Humidity: A factor in the appropriate positioning of a photovoltaic power station. *Renewable Energy* 6(3), April 1995, S. 313–316.
- [Heat13] Heaton Research. Encog Machine Learning Framework, 2013. <http://www.heatonresearch.com/encog>, Zugriff am 17. September 2013.
- [HHLL99] A. Hammer, D. Heinemann, E. Lorenz und B. Lückehe. Short-term forecasting of solar radiation: a statistical approach using satellite data. *Solar Energy* 67(1–3), Juli 1999, S. 139–150.
- [KaCz80] F. Kasten und G. Czeplak. Solar and terrestrial radiation dependent on the amount and type of cloud. *Solar Energy* 24(2), 1980, S. 177–189.
- [Kluc79] T. Klucher. Evaluation of models to predict insolation on tilted surfaces. *Solar Energy* 23(2), 1979, S. 111–114.

- [LHHB09] E. Lorenz, J. Hurka, D. Heinemann und H. G. Beyer. Irradiance forecasting for the power prediction of grid-connected photovoltaic systems. *Selected Topics in Applied Earth Observations and Remote Sensing, IEEE Journal of* 2(1), 2009, S. 2–10.
- [LHKH⁺07] E. Lorenz, J. Hurka, G. Karampela, D. Heinemann, H. G. Beyer und M. Schneider. Qualified forecast of ensemble power production by spatially dispersed grid-connected PV systems. *Measurement*, 2007.
- [LiJo63] B. Y. Liu und R. C. Jordan. The long-term average performance of flat-plate solar-energy collectors: with design data for the US, its outlying possessions and Canada. *Solar Energy* 7(2), 1963, S. 53–74.
- [Lind12] A. M. Linder. *Erzeugungsprognose dezentraler Einspeiser in Smart Grids*. Diplomarbeit, Karlsruher Institut für Technologie, Januar 2012.
- [LSHH⁺11] E. Lorenz, T. Scheidsteger, J. Hurka, D. Heinemann und C. Kurz. Regional PV power prediction for improved grid integration. *Progress in Photovoltaics: Research and Applications* 19(7), 2011, S. 757–771.
- [MeSK12] S. Mekhilef, R. Saidur und M. Kamalisarvestani. Effect of dust, humidity and air velocity on efficiency of photovoltaic cells. *Renewable and Sustainable Energy Reviews* 16(5), Juni 2012, S. 2920–2925.
- [MIDC00] N. MIDC. National Renewable Energy Laboratory Measurement and Instrumentation Data Center (NREL MIDC) Solar Position and Intensity (SOLPOS) Calculator, 2000. <http://www.nrel.gov/midc/solpos/-solpos.html>, Zugriff am 8. April 2013.
- [MuGu00] T. Muneer und M. Gul. Evaluation of sunshine and cloud cover based models for generating solar radiation data. *Energy Conversion and Management* 41(5), 2000, S. 461–482.
- [NoMK08] A. M. Noorian, I. Moradi und G. A. Kamali. Evaluation of 12 models to estimate hourly diffuse irradiation on inclined surfaces. *Renewable Energy* 33(6), Juni 2008, S. 1406–1412.
- [Patt97] D. W. Patterson. *Künstliche neuronale Netze: das Lehrbuch*. Prentice Hall, Haar bei München [u.a. 1997.
- [Pi13] R. Pi. Raspberry Pi, September 2013. http://en.wikipedia.org/w/index.php?title=Raspberry_Pi, Zugriff am 11. September 2013.

- [PSAS⁺86] R. Perez, R. Stewart, C. Arbogast, R. Seals und J. Scott. An anisotropic hourly diffuse radiation model for sloping surfaces: Description, performance validation, site dependency evaluation. *Solar Energy* 36(6), 1986, S. 481–497.
- [PSIS⁺87] R. Perez, R. Seals, P. Ineichen, R. Stewart und D. Menicucci. A new simplified version of the perez diffuse irradiance model for tilted surfaces. *Solar Energy* 39(3), 1987, S. 221–231.
- [Quas12] V. Quaschnig. Sonnenstrom selbst genutzt - die solare Revolution. *Der fortschrittliche Landwirt* (14), 2012, S. 70–71.
- [Quas13] V. Quaschnig. *Regenerative Energiesysteme Technologie - Berechnung - Simulation; mit 117 Tabellen*. Hanser, München. 2013.
- [ReBD90] D. Reindl, W. Beckman und J. Duffie. Diffuse fraction correlations. *Solar Energy* 45(1), 1990, S. 1–7.
- [Sama00] Z. Samani. Estimating Solar Radiation and Evapotranspiration Using Minimum Climatological Data. *Journal of Irrigation and Drainage Engineering* 126(4), 2000, S. 265–267.
- [ScSa96] H. Schmidt und D. U. Sauer. Wechselrichter-Wirkungsgrade. *Sonnenenergie* 21(Nr.4), 1996, S. 43–47.
- [SMA10] SMA. Installation Guide PV Inverter Sunny Boy 3000TL/4000TL/5000TL, 2010. http://files.sma.de/dl/5692/SB30TL_40TL_50TL-IA-IEN120231.pdf, Zugriff am 20. September 2013.
- [SMA12] SMA. Unternehmensprofil, 2012. <http://www.sma.de/unternehmen/ueber-sma/unternehmensprofil.html>, Zugriff am 28.09.2013.
- [SMA13] SMA. Sunny Explorer, 2013. <http://www.sma.de/produkte/monitoring-systems/sunny-explorer.html#Technische-Daten-3898>, Zugriff am 10. September 2013.
- [SMAs13] SMAspot. SMAspot, Juni 2013. <https://code.google.com/p/sma-spot/>, Zugriff am 1. Juli 2013.
- [SuvK98] I. Supit und R. van Kappel. A simple method to estimate global radiation. *Solar Energy* 63(3), September 1998, S. 147–160.
- [TaSC10] C. Tao, D. Shanxu und C. Changsong. Forecasting power output for grid-connected photovoltaic power system without using solar radiation

- measurement. In *2010 2nd IEEE International Symposium on Power Electronics for Distributed Generation Systems (PEDG)*, 2010, S. 773–777.
- [Tava13] M. P. Tavares. owmClient, 2013. <https://github.com/migtavares/owmClient>, Zugriff am 13. September 2013.
- [TeCo77] R. C. Temps und K. Coulson. Solar radiation incident upon slopes of different orientations. *Solar Energy* 19(2), 1977, S. 179–184.
- [Ukol13a] D. Ukoloff. OpenWeatherMap, 2013. <http://openweathermap.org/>, Zugriff am 9. September 2013.
- [Ukol13b] D. Ukoloff. OpenWeatherMap – enthusiasts do weather, Januar 2013. <http://openweathermap.org/blog/2013/01/openweathermap/>, Zugriff am 9. September 2013.
- [Vign07] F. Vignola. Shading on PV Systems: Estimating the Effect. In *Proceedings of the Solar Conference*, Band 1, 2007, S. 291.
- [Watt09] H. Watter. Nachhaltige Energiesysteme. In *Nachhaltige Energiesysteme*, S. 1–3. Vieweg+Teubner, Januar 2009.
- [WBHG⁺03] S. R. Williams, T. Betts, T. Helf, R. Gottschalg, H. Beyer und D. Infield. Modelling long-term module performance based on realistic reporting conditions with consideration to spectral effects. In *Proceedings of 3rd World Conference on Photovoltaic Energy Conversion, 2003*, Band 2, 2003, S. 1908–1911.
- [YoSF07] A. Yona, T. Senjyu und T. Funabashi. Application of Recurrent Neural Network to Short-Term-Ahead Generating Power Forecasting for Photovoltaic System. In *IEEE Power Engineering Society General Meeting, 2007*, 2007, S. 1–6.
- [YSSF⁺08] A. Yona, T. Senjyu, A. Saber, T. Funabashi, H. Sekine und C.-H. Kim. Application of neural network to 24-hour-ahead generating power forecasting for PV system. In *2008 IEEE Power and Energy Society General Meeting - Conversion and Delivery of Electrical Energy in the 21st Century*, 2008, S. 1–6.